

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

Выпускная квалификационная работа

на тему:

**Экспериментальное исследование эффективности алгоритмов
обнаружения мошенничества на разнородных наборах данных**

Выполнила студентка:

Группы БПМИ229, 4 курса

Брель Мария Фёдоровна

ФИО студента

Научный руководитель:

Паточенко Евгений Анатольевич, магистр

ФИО, научная степень (если есть)

Старший преподаватель

Должность

Департамент больших данных и информационного поиска

Место работы (организация или департамент НИУ ВШЭ)

Содержание

Аннотация	4
Abstract	5
1 Введение	6
1.1 Актуальность темы	6
1.2 Проблема сравнимости исследований	7
1.3 Цель и задачи работы	8
1.4 Научная новизна	9
1.5 Практическая значимость	9
2 Обзор литературы	10
2.1 Постановка задачи обнаружения мошенничества	10
2.2 Классические методы машинного обучения	11
2.3 Методы работы с несбалансированными данными	12
2.4 Методы глубинного обучения	13
2.5 Графовые нейронные сети	15
2.6 Бенчмарки и системы сравнения	17
2.7 Инструменты и библиотеки	17
2.8 Итоги обзора литературы	18
3 Данные	19
3.1 Принципы отбора наборов данных	19
3.2 Характеристика наборов данных	19
3.3 Мета-признаки наборов данных	23
3.4 Предобработка данных	27
4 Алгоритмы	31
4.1 Логистическая регрессия (LR)	31
4.2 Случайный лес (RF)	31
4.3 XGBoost	32
4.4 Многослойный перцептрон (MLP)	33
4.5 Вариационный автокодировщик (VAE)	34
4.6 Графовая сверточная сеть (GCN)	35

4.7	Graph Attention Network (GAT)	35
4.8	GraphSAGE	36
4.9	Сводная таблица гиперпараметров	37
5	Дизайн экспериментов	38
5.1	Протокол оценки	38
5.2	Метрики оценки	38
5.3	Статистическое тестирование	40
5.4	Вычислительные ресурсы	40
6	Экспериментальные результаты	41
6.1	Основные результаты по AUPRC	41
6.2	Результаты по F1-мере	42
6.3	Результаты по Precision@K	43
6.4	Анализ по доменам	44
6.5	Результаты графовых методов	45
6.6	Статистическое тестирование	46
6.7	Анализ вычислительной стоимости	46
7	Анализ и обсуждение	48
7.1	Проверка гипотез: влияние свойств данных на эффективность алгоритмов	48
7.2	Ключевые количественные закономерности	49
7.3	Сравнение семейств алгоритмов: итоги	49
7.4	Практические рекомендации	49
7.5	Ограничения исследования	50
8	Заключение	52
8.1	Итоги работы и основные выводы	52
8.2	Вклад в область	52
8.3	Направления дальнейших исследований	53
	Список литературы	55

Аннотация

Ежегодно мошенничество наносит огромные убытки в банковской сфере, электронной коммерции и социальных сетях. Для автоматического выявления мошеннических действий широко применяются методы машинного обучения. За последние годы исследователями предложено множество алгоритмов — от классических статистических моделей до современных графовых нейронных сетей. Однако большинство опубликованных работ тестируют свой алгоритм лишь на одном наборе данных, что затрудняет понимание того, какой метод лучше всего подходит для новой практической задачи.

Целью данной работы является масштабное экспериментальное сравнение алгоритмов обнаружения мошенничества на разнородных наборах данных. В рамках проекта проведена серия экспериментов с несколькими алгоритмами на различных наборах данных из бенчмарка Fraud Dataset Benchmark (FDB), включающих данные о кредитных транзакциях, финансовых операциях и взаимодействиях в социальных сетях. Исследованы зависимости производительности классических моделей, методов глубокого обучения и графовых нейронных сетей от характеристик данных — размера, степени несбалансированности классов и наличия связей между объектами. Результатом работы является набор практических рекомендаций для выбора наиболее подходящего алгоритма в зависимости от типа данных о мошенничестве, что полезно как исследователям, так и практикам, разрабатывающим системы обнаружения мошенничества.

Ключевые слова: обнаружение мошенничества, машинное обучение, экспериментальное сравнение, несбалансированные данные, FDB, графовые нейронные сети, мета-обучение, XGBoost, GraphSAGE.

Abstract

Fraud causes enormous annual losses in banking, e-commerce, and social networks. Machine learning methods are widely used for automatic fraud detection. In recent years, researchers have proposed many algorithms — from classical statistical models to modern graph neural networks. However, most published works test their algorithm on only one dataset, making it difficult to determine which method is best suited for a new practical task.

The aim of this work is a large-scale experimental comparison of fraud detection algorithms on heterogeneous datasets. A series of experiments was conducted with several algorithms on various datasets from the Fraud Dataset Benchmark (FDB), including data on credit transactions, financial operations, and social network interactions. The dependence of performance of classical models, deep learning methods, and graph neural networks on data characteristics — size, class imbalance, and the presence of relationships between objects — was investigated. The result of the work is a set of practical recommendations for selecting the most appropriate algorithm depending on the type of fraud data, which is useful for both researchers and practitioners developing fraud detection systems.

Keywords: fraud detection, machine learning, benchmarking, class imbalance, FDB, graph neural networks, meta-learning, XGBoost, GraphSAGE.

1 Введение

1.1 Актуальность темы

Ежегодный ущерб мировой экономики от мошенничества достигает триллионов долларов. По данным Global Anti-Scam Alliance (GASA), в 2024 году глобальные потери от мошеннических схем превысили **1,03 трлн долл.**, при этом лишь 4% жертв смогли полностью вернуть свои средства [15]. В этих условиях многие области (в основном банковский сектор, электронная коммерция и социальные сети) активно внедряют автоматизированные системы для выявления мошеннических действий. По данным Juniper Research, по мере того как мошенничество становится все более изощренным, рынок обнаружения мошенничества с использованием искусственного интеллекта к 2030 году должен вырасти до 39,1 миллиарда долларов.

Для борьбы с этой угрозой широко применяются методы машинного обучения. За последние годы исследователями предложено множество подходов — от классических статистических моделей до современных графовых нейронных сетей (GNN). Последние особенно перспективны благодаря способности учитывать связи между объектами, что критически важно для выявления сложных мошеннических сетей [12]. Однако обнаружение мошенничества сопряжено с рядом фундаментальных трудностей, в частности с экстремальной несбалансированностью классов — доля мошеннических операций в реальных данных может составлять менее 0.2% [5] и колебаться при атаках.

Несмотря на обилие публикаций, большинство работ тестируют свои алгоритмы лишь на одном-двух наборах данных. Отсутствие систематических кросс-доменных сравнений на разнородных данных существенно затрудняет выбор оптимального метода для новой практической задачи. Лишь недавно появились первые попытки создания единых бенчмарков: Fraud Dataset Benchmark (FDB) объединяет публичные наборы данных по различным задачам — от обнаружения мошеннических транзакций до модерации контента [24]. Тем не менее масштабные сравнительные исследования с участием современных графовых и глубоких методов на столь широкой выборке данных остаются единичными.

Таким образом, актуальность данной работы обусловлена:

- колоссальными экономическими потерями от мошенничества, требующими внедрения надёжных систем детекции;
- многообразием существующих алгоритмов при отсутствии систематических рекомендаций по их выбору;

- появлением новых репрезентативных бенчмарков (FDB), создающих основу для воспроизводимых сравнительных экспериментов;
- необходимостью учёта специфических свойств данных о мошенничестве (несбалансированность, наличие связей, разнородность доменов).

Проведённое в рамках диплома масштабное сравнение алгоритмов на разнородных наборах данных призвано заполнить этот пробел и предоставить практические ориентиры для разработчиков систем обнаружения мошенничества.

1.2 Проблема сравнимости исследований

Несмотря на обилие публикаций в области обнаружения мошенничества, отрасль страдает от системной проблемы: большинство работ тестируют предложенный алгоритм лишь на одном наборе данных [20, 24]. Причины этого разнообразны:

- **Конфиденциальность.** Реальные данные о транзакциях или фейковых аккаунтах коммерчески чувствительны и редко публикуются в полном объёме. Компании, как правило, предоставляют лишь выборки или анонимизированные версии. Как отмечается в работе [10], даже анонимизированные данные финансовых учреждений содержат риски деанонимизации, что ограничивает их открытое распространение.
- **Разнородность.** Наборы данных о мошенничестве из разных доменов (финансы, e-commerce, социальные сети) настолько различаются по структуре, что исследователи нередко не видят смысла в их совместном рассмотрении. Например, признаки мошенничества с кредитными картами (сумма, время, мерчант) принципиально отличаются от признаков фейковых отзывов (текст, рейтинг, паттерны публикаций) или признаков бот-аккаунтов в социальных сетях (граф друзей, частота постов, метаданные).
- **Традиционность.** Существуют «канонические» наборы данных (например, датасет транзакций ULB по банковским картам [11]), которые используются повторно из работы в работу, создавая иллюзию сравнимости результатов. Систематический обзор [20] показал, что более 60% работ в области обнаружения мошенничества с 2015 по 2022 год использовали только один набор данных, и в 38% случаев этим набором был именно ULB.

В результате возникает ситуация, при которой невозможно ответить на практически важный вопрос: *какой алгоритм следует применить к данному конкретному набору данных*

о мошенничестве? Модель, показывающая рекордные результаты на данных о кредитных картах одного банка, может оказаться значительно хуже простой логистической регрессии на данных о фейковых отзывах или фиктивных аккаунтах в социальной сети. Как показано в исследовании [10], AUC модели, достигнутой на одном датасете, может упасть на 20–30% при тестировании на другом датасете из того же домена, не говоря уже о кросс-доменном переносе.

1.3 Цель и задачи работы

Цель данной выпускной квалификационной работы — провести масштабное экспериментальное сравнение алгоритмов обнаружения мошенничества на разнородных наборах данных и на основе результатов разработать обоснованные практические рекомендации по выбору алгоритма в зависимости от характеристик данных.

Для достижения цели поставлены следующие **задачи**:

- 1 Провести обзор современных методов машинного обучения, применяемых для обнаружения мошенничества, включая классические алгоритмы (логистическая регрессия, случайный лес, XGBoost), методы глубокого обучения (многослойный перцептрон, вариационный автокодировщик) и графовые нейронные сети (GraphSAGE).
- 2 Реализовать единый пайплайн предобработки данных и обучения моделей, обеспечивающий воспроизводимость экспериментов.
- 3 Сформировать выборку из 12+ разнородных наборов данных, различающихся по домену (финансы, электронная коммерция, социальные сети), размеру, степени несбалансированности классов и наличию графовой структуры.
- 4 Реализовать и настроить восемь алгоритмов обнаружения мошенничества: логистическую регрессию, случайный лес, XGBoost, многослойный перцептрон (MLP), вариационный автокодировщик (VAE) и графовые нейронные сети (GraphSAGE, GCN, GAT).
- 5 Провести систематические эксперименты с повторами для оценки производительности каждого алгоритма на каждом наборе данных с использованием метрик, корректных для несбалансированных задач (AUPRC, F1-мера, Precision@K).
- 6 Выявить корреляции между характеристиками данных и рангами производительности алгоритмов.

- 7 Сформулировать практические рекомендации для специалистов, разрабатывающих системы обнаружения мошенничества.

1.4 Научная новизна

Научная новизна данной работы заключается в следующем:

- 1 Впервые выполнено систематическое сравнение трёх семейств алгоритмов обнаружения мошенничества — классических методов машинного обучения, методов глубокого обучения и графовых нейронных сетей — на единой выборке из 12 разнородных наборов данных с использованием унифицированной методологии предобработки и оценки.
- 2 Выявлены и количественно оценены зависимости между ключевыми характеристиками данных (степень несбалансированности классов, размер выборки, наличие и плотность графовой структуры) и относительной производительностью различных алгоритмов.
- 3 Выявлены и количественно оценены значимые корреляции между мета-признаками (дисбаланс, размер выборки) и относительной производительностью алгоритмов.

1.5 Практическая значимость

Практическая значимость работы определяется следующим:

- 1 Разработанные рекомендации позволяют специалистам по обработке данных и разработчикам систем обнаружения мошенничества сократить время на первоначальный выбор алгоритма. На основе проведённых экспериментов сформулированы конкретные рекомендации в зависимости от свойств данных (дисбаланс классов, объём выборки, наличие графовой структуры), что даёт возможность обоснованно выбрать метод без перебора всех возможных вариантов.
- 2 Выявленные в работе корреляции между мета-признаками (размером выборки, коэффициентом дисбаланса) и производительностью алгоритмов могут быть использованы при проектировании автоматизированных пайплайнов для задач обнаружения мошенничества, снижая порог входа для новых доменов.
- 3 Результаты экспериментов и собранные мета-признаки наборов данных могут служить основой для дальнейших исследований в области сравнительного анализа алгоритмов обнаружения мошенничества и мета-обучения.

2 Обзор литературы

2.1 Постановка задачи обнаружения мошенничества

Задача обнаружения мошенничества в большинстве случаев формулируется как задача бинарной классификации: по вектору признаков объекта $\mathbf{x} \in \mathbb{R}^d$ необходимо предсказать метку $y \in \{0, 1\}$, где $y = 1$ соответствует мошеннической операции. Однако, в отличие от стандартной классификации, здесь присутствует ряд специфических особенностей, которые необходимо учитывать при выборе модели.

- 1 **Сильный дисбаланс классов.** Доля мошеннических объектов в реальных данных часто составляет менее 0,2% от общего объёма. Это делает традиционные метрики вроде ассигасы бессмысленными: модель, предсказывающая всегда «норма», будет иметь ассигасу $> 99\%$, но не обнаружит ни одного мошенничества.
- 2 **Концептуальный дрейф (Concept Drift)** Мошенники постоянно адаптируют свои схемы, поэтому распределение данных меняется со временем. Модель, обученная на исторических данных, требует регулярного обновления [35].
- 3 **Асимметрия стоимости ошибок.** Пропуск мошенничества (false negative) обходится значительно дороже, чем ложная тревога (false positive). Как показано в масштабном сравнении на 9 датасетах, при бизнес-ограничении 5% на частоту ложных срабатываний свёрточные спайковые нейронные сети демонстрируют наилучшие результаты [2].
- 4 **Реляционная структура.** Мошеннические действия часто совершаются группами, с использованием общих устройств, IP-адресов или счетов. Графовые методы позволяют явно моделировать такие связи, что подтверждается современными исследованиями [19, 9].
- 5 **Интерпретируемость.** Регуляторные требования часто обязывают организации предоставлять объяснение причин отказа в проведении транзакции. Однако полное раскрытие логики работы антифрод-систем создаёт дополнительные риски: детальное описание признаков, по которым операция была признана подозрительной, может быть использовано злоумышленниками для целенаправленного обхода механизмов защиты. Таким образом, перед разработчиками встаёт двойная задача: с одной стороны, обеспечить соответствие регуляторным требованиям в части объяснимости решений, а с другой — не допустить утечки критически важной информации о правилах детекти-

рования. В связи с этим предпочтение отдаётся моделям, которые позволяют анализировать внутренние механизмы принятия решений без полного раскрытия чувствительных параметров. Кроме того, интерпретируемость необходима и самой компании для верификации гипотез о мошеннических паттернах и корректной настройки системы. Использование моделей-«чёрных ящиков», без возможности объяснения их поведения, затрудняет как выполнение регуляторных требований, так и оперативное выявление новых схем злоумышленников.

2.2 Классические методы машинного обучения

2.2.1 Логистическая регрессия

Логистическая регрессия (LR) является базовым методом для бинарной классификации. Она моделирует вероятность принадлежности к положительному классу через сигмоидальную функцию:

$$P(y = 1 \mid \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^\top \mathbf{x} + b)}}, \quad (1)$$

где $\mathbf{w}$ — вектор весов, b — смещение. Обучение обычно производится минимизацией бинарной кросс-энтропии с L_2 -регуляризацией (гребневая регрессия). Преимущества LR — интерпретируемость и высокая скорость обучения. Недостаток — линейность разделяющей границы, что недостаточно для сложных зависимостей.

2.2.2 Деревья решений и ансамбли

Деревья решений разбивают пространство признаков рекурсивными бинарными вопросами вида $x_j \leq t$. Они способны улавливать нелинейности и взаимодействия признаков, но склонны к переобучению при большой глубине.

Случайный лес (Random Forest) усредняет предсказания множества деревьев, каждое из которых обучается на случайной подвыборке данных (bootstrap) и использует случайное подмножество признаков для каждого разбиения. Это снижает дисперсию и предотвращает переобучение. Случайный лес устойчив к выбросам и даёт встроенную оценку важности признаков. В задаче обнаружения мошенничества он часто превосходит логистическую регрессию [4].

Градиентный бустинг строит ансамбль последовательно, где каждое следующее дерево корректирует ошибки предыдущих. Обновление модели выглядит как

$$F_t(\mathbf{x}) = F_{t-1}(\mathbf{x}) + \eta \cdot h_t(\mathbf{x}), \quad (2)$$

где h_t аппроксимирует отрицательный градиент функции потерь, а η — скорость обучения. **XGBoost** добавляет регуляризацию листовых весов и использует гистограммный метод для ускорения, что делает его одним из самых эффективных алгоритмов для табличных данных. **LightGBM** дополнительно оптимизирован для больших наборов данных за счёт роста дерева по листьям и техники GOSS. Сравнительное исследование на высоко несбалансированных транзакционных данных подтвердило превосходство LightGBM и случайного леса над логистической регрессией и GRU [33].

Масштабное сравнение 9 методов на 9 датасетах показало, что XGBoost и случайный лес демонстрируют наилучшие результаты по большинству метрик [2].

2.2.3 Метод опорных векторов

Метод опорных векторов (SVM) строит гиперплоскость с максимальным зазором между классами. В задачах с сильным дисбалансом и большими объёмами данных SVM редко применяется из-за вычислительной сложности $O(n^2)$ – $O(n^3)$. В данном исследовании SVM не рассматривается.

2.3 Методы работы с несбалансированными данными

Проблема классового дисбаланса является одной из ключевых в задачах обнаружения мошенничества: доля аномальных транзакций в реальных данных часто не превышает долей процента. Если обучать модель на таком наборе без специальной обработки, она будет склонна игнорировать редкий класс, достигая высокой точности за счёт предсказания «нормы» для всех объектов. Для преодоления этого эффекта разработано несколько семейств методов, которые условно можно разделить на модифицирующие данные и модифицирующие алгоритм.

- 1 **Оверсэмплинг (генерация синтетических примеров)**. Метод SMOTE [6] создаёт новые объекты миноритарного класса путём линейной интерполяции между реальными примерами:

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \alpha(\mathbf{x}_k - \mathbf{x}_i), \quad \alpha \sim U(0, 1), \quad (3)$$

где $\mathbf{x}_i$ и $\mathbf{x}_k$ — два случайных соседних объекта из меньшинства, а α — случайный коэффициент. Это позволяет сбалансировать выборку без потери информации.

- 2 **Взвешивание классов (cost-sensitive learning).** Вместо изменения данных можно модифицировать функцию потерь, назначив большую стоимость ошибки на мошенническом объекте. Обычно вес положительного класса устанавливают обратно пропорционально его частоте: $w_+ = N_-/N_+$, где N_- и N_+ — количество нормальных и мошеннических примеров соответственно. Такой подход не увеличивает объём выборки и легко реализуется в большинстве алгоритмов машинного обучения.
- 3 **Диффузионные методы генерации данных.** В последние годы активно развиваются подходы на основе диффузионных моделей, способные создавать более реалистичные синтетические примеры, чем SMOTE. Например, метод FRACTAL [8] использует трансформер-управляемую диффузионную сеть и на бенчмарках кредитного мошенничества достигает F1=0,89 при времени обучения около 30 минут. Такие методы представляют интерес для задач с крайне высоким дисбалансом, однако их вычислительная сложность пока ограничивает широкое применение.
- 4 **Федеративное обучение с синтетическими данными.** Совсем недавно появилось новое направление - совместное обучение моделей на данных нескольких финансовых организаций без прямого обмена конфиденциальной информацией. Федеративный подход в сочетании с генерацией синтетических примеров (например, Federated-SMOTE или Federated-GAN) позволяет повысить качество обнаружения мошенничества на 17–21% по метрике PR-AUC по сравнению с обучением каждого банка изолированно [5]. Хотя в данной работе федеративное обучение не реализуется, этот метод упоминается как перспективное направление для будущих исследований в поиске мошеннических действий.

Выбор конкретной стратегии борьбы с дисбалансом зависит от характеристик данных (степени дисбаланса, размера выборки) и используемого алгоритма [10]. В рамках данной работы основное внимание уделяется взвешиванию классов и оверсэмплингу (SMOTE) как наиболее универсальным и вычислительно эффективным методам. Сравнение их эффективности на разных наборах данных является одной из задач экспериментального исследования.

2.4 Методы глубинного обучения

В данном разделе рассматриваются подходы, основанные на глубинных нейронных сетях. В отличие от классических методов, они способны автоматически извлекать иерархи-

ческие представления признаков, однако требуют значительных объёмов данных и вычислительных ресурсов.

2.4.1 Многослойный перцептрон (MLP)

MLP является базовой архитектурой глубинного обучения. Он состоит из нескольких полносвязных слоёв, каждый из которых применяет линейное преобразование с последующей нелинейной активацией. Формально слой l вычисляет:

$$\mathbf{h}^{(l)} = f(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}), \quad (4)$$

где $\mathbf{W}^{(l)}$ и $\mathbf{b}^{(l)}$ — обучаемые веса и смещения, а f — функция активации (обычно ReLU: $f(x) = \max(0, x)$). Выход последнего слоя — вероятность мошенничества. Согласно теореме Хорника [21], MLP с одним скрытым слоем способен аппроксимировать любую непрерывную функцию, однако на практике глубокие сети с несколькими слоями требуют больше данных, но могут выявлять более сложные закономерности.

В антифродде MLP работает как обычный классификатор: по набору признаков транзакции (сумма, время, категория продавца и т.д.) он предсказывает, является ли операция мошеннической. При большом объёме размеченных данных MLP способен выявлять сложные нелинейные зависимости, недоступные линейным моделям. Для ускорения сходимости и предотвращения переобучения применяются batch normalization и dropout.

2.4.2 Автокодировщики и вариационные автокодировщики (VAE)

Автокодировщик состоит из двух частей: кодировщика и декодировщика. Кодировщик сжимает входной объект до небольшого латентного вектора (бутылочного горлышка), а декодировщик восстанавливает исходный объект из этого сжатого представления. Сеть обучается минимизировать ошибку восстановления. Если обучить автокодировщик только на нормальных (немошеннических) примерах, то на мошеннических объектах ошибка восстановления $\|\mathbf{x} - \hat{\mathbf{x}}\|^2$ будет значительно выше, что позволяет использовать её в качестве меры аномальности.

В задачах антифрода автокодировщик обучают только на нормальных (немошеннических) транзакциях. В этом случае он хорошо восстанавливает обычные операции, но плохо — мошеннические, так как они отличаются по структуре. Величина ошибки восстановления служит индикатором аномалии.

Вариационный автокодировщик (VAE) [25] отличается тем, что кодировщик предсказывает не один латентный вектор, а параметры распределения (среднее и дисперсию).

$$\mathcal{L}_{\text{VAE}} = \underbrace{\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x}|\mathbf{z})]}_{\text{ожидаемая ошибка восстановления}} - \underbrace{D_{\text{KL}}(q_\phi(\mathbf{z}|\mathbf{x}) \parallel p(\mathbf{z}))}_{\text{регуляризатор}}, \quad (5)$$

где $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ — априорное распределение. VAE позволяет не только обнаруживать аномалии, но и генерировать новые объекты, похожие на обучающие. Обычно в антифродде VAE применяется в полуконтролируемом режиме — когда размеченных примеров мошенничества недостаточно для обучения обычного классификатора. В данном исследовании VAE используется именно в таком режиме.

2.4.3 Трансформеры

Трансформеры основаны на механизме внимания (attention) [31]. Вместо последовательной обработки данных, как в рекуррентных сетях, трансформер вычисляет попарные связи между всеми элементами последовательности и определяет, какие из них наиболее важны для предсказания. Это позволяет эффективно работать с длинными последовательностями, например, с историей транзакций пользователя.

Для табличных данных была предложена адаптация — TabTransformer [22], который преобразует категориальные признаки в эмбединги через механизм внимания. Однако систематические сравнения [16] показывают, что на стандартных табличных бенчмарках XGBoost зачастую превосходит трансформеры, особенно при ограниченном объёме данных. В данной работе трансформеры не используются из-за высокой вычислительной сложности и отсутствия доказанного преимущества на табличных признаках.

2.5 Графовые нейронные сети

Мошенничество часто носит организованный характер. Например, несколько аккаунтов могут быть связаны общим устройством, мошеннические транзакции — проходить через одни и те же счета, а боты в соцсетях — подписываться друг на друга. Обычные методы машинного обучения смотрят на каждый объект по отдельности и не видят этих связей. Графовые нейронные сети (GNN) позволяют явно учитывать связи между объектами, используя информацию о соседях.

В графе узлы — это объекты (транзакции, аккаунты, пользователи), а рёбра — связи между ними (общее устройство, перевод денег, подписка). У каждого узла есть набор

признаков: для транзакции это сумма, время, категория продавца и т.д. GNN вычисляют эмбединги узлов итеративным агрегированием информации от соседей. Этот принцип называется передачей сообщений (message passing) [14].

2.5.1 GCN (графовая свёрточная сеть)

GCN [26] — одна из первых и самых простых GNN, требует весь граф до обучения. Она использует нормализованную агрегацию в спектральной области:

$$\mathbf{H}^{(k)} = \sigma\left(\tilde{\mathbf{D}}^{-1/2} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-1/2} \mathbf{H}^{(k-1)} \mathbf{W}^{(k)}\right), \quad (6)$$

где $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}$ — матрица смежности с петлями, $\tilde{\mathbf{D}}$ — матрица степеней.

2.5.2 GraphSAGE

GraphSAGE [17] решает главное ограничение GCN: он не требует, чтобы граф был известен целиком, что позволяет его использовать в реальных антифродных системах, где информация о событиях поступает непрерывно. GraphSAGE индуктивно берёт случайную выборку соседей и учится агрегировать их признаки.

GraphSAGE эффективно выявляет подозрительные паттерны: даже если отдельная транзакция выглядит нормально, но совершена с устройства, уже связанного с мошенничеством, модель это заметит. Исследования показывают высокую эффективность данного метода: на датасете Bitcoin Elliptic модель достигает F1=0,8981 на будущих непросмотренных транзакциях [3]

2.5.3 Современные разработки

У стандартных GNN есть слабое место: они предполагают, что у соседних узлов одинаковые метки (честные рядом с честными, мошенники рядом с мошенниками). Но мошенники намеренно связываются с честными пользователями, чтобы их не заподозрили. Это называется «камуфляж мошенничества» [27, 9].

Для борьбы с этим разработаны новые подходы:

- **MIGFD** разделяет признаки на содержательные и стилистические, чтобы лучше отличать мошенников от честных. На пяти реальных датасетах метод обошёл 12 современных моделей [27].

- **ADSCMP** интегрирует лёгкие механизмы внимания, что позволяет во время передачи сообщений отделять «хороших» соседей от «плохих» и неизвестных. На Amazon модель достигла AUC 97,91% [34].
- **DPF-GFD** использует специальные фильтры для выделения ключевых структурных паттернов в графе [19].
- **HIMVN** включает модуль восприятия кросс-вью несоответствий для выявления замаскированного мошеннического поведения. На шести финансовых датасетах модель улучшила AUC на 6–40% по сравнению с лучшими аналогами [9].

Эти разработки подчёркивают важность использования современных графовых методов и их активное развитие. В данной работе GraphSAGE используется как основной графовый алгоритм.

2.6 Бенчмарки и системы сравнения

Fraud Dataset Benchmark (FDB) [24] — первый крупный бенчмарк, объединяющий более 30 наборов данных из разных доменов с унифицированной предобработкой. Авторы показали, что ни один алгоритм не доминирует на всех данных.

Обширное сравнение 9 методов на 9 датасетах с использованием 9 метрик, выполненное с применением скорректированного теста Фридмана и построка Неменьи, определило, что XGBoost и случайный лес показывают наилучшие результаты по большинству метрик. При бизнес-ограничении 5% FPR свёрточные спайковые нейронные сети (CSNN) продемонстрировали лучшие показатели [2].

Всесторонний обзор систематизировал исследования по ИИ для обнаружения финансового мошенничества, опубликованные в период с 2015 по 2025 год, охватывая методы машинного и глубокого обучения, включая модели на основе деревьев, нейронные сети и графовые методы [1].

2.7 Инструменты и библиотеки

Для реализации экспериментов использовались следующие библиотеки с открытым исходным кодом:

- **scikit-learn** [29] — для логистической регрессии, случайного леса и метрик.
- **XGBoost** [7] — для градиентного бустинга.

- PyTorch [28] — для реализации MLP, VAE и GraphSAGE.
- PyTorch Geometric [13] — для операций с графами.
- NumPy [18], Pandas [30], Matplotlib [23] — для обработки данных и визуализации.

2.8 Итоги обзора литературы

Проведённый обзор показывает:

- Для табличных данных наилучшие результаты стабильно показывает XGBoost, что подтверждается многочисленными сравнительными исследованиями.
- Графовые методы (особенно GraphSAGE и современные разработки, такие как ADSCMP, DPF-GFD, HIMVN) дают дополнительный прирост при наличии реляционной структуры.
- Проблема дисбаланса остаётся ключевой, новые методы на основе диффузионных моделей и федеративного обучения показывают многообещающие результаты.
- Существует потребность в систематическом сравнении алгоритмов на разнородных наборах данных, что и является целью данной работы.

3 Данные

3.1 Принципы отбора наборов данных

Из доступных источников данных были данных отобраны 11 датасетов, обеспечивающих наибольшую репрезентативность по следующим критериям:

- 1 **Домен:** финансовые транзакции, электронная коммерция, социальные сети.
- 2 **Размер:** от нескольких тысяч до нескольких сотен тысяч объектов.
- 3 **Коэффициент несбалансированности (IR):** от 5.25:1 (84% мошенничества) до 1:770 (0.13% мошенничества).
- 4 **Структура:** чисто табличные данные и данные с графовой структурой.
- 5 **Достоверность:** реальные (возможно анонимизированные) данные с платформ или синтетические данные от авторитетных источников

3.2 Характеристика наборов данных

В таблице 3.1 приведены ключевые характеристики отобранных наборов данных.

Таблица 3.1: Характеристики наборов данных

Датасет	Домен	N	d	Доля, %	IR	Год
Credit Card Fraud	Финансы	284 807	30	0.17	577:1	2015
IEEE-CIS	Финансы	590 540	393	3.50	28:1	2019
PaySim	Финансы	6 354 407	10	0.13	770:1	2016
AIZBank	Финансы	45 211	17	11.70	8.5:1	2025
Elliptic (Bitcoin)	Финансы	203 769	168	9.80	9.2:1	2019
Amazon Reviews	E-commerce	11 944 805	25	8.00	12:1	2017
Yelp Reviews	E-commerce	67 395	32	14.50	7:1	2020
Click Fraud	E-commerce	200 000 000	7	0.25	400:1	2018
Social Honeypot	Соцсети	41 499	6	53.55	1.15:1	2012
MGTAB	Соцсети	10 199	788	35.80	1.79:1	2022
Cresci-2017	Соцсети	14 368	19	57.00	1.33:1	2017
Midterm-2018	Соцсети	75 896	19	84.00	5,25:1	2018

3.2.1 Credit Card Fraud

Один из наиболее цитируемых в литературе тематических наборов данных, содержит 284 807 транзакций по кредитным картам европейских держателей за сентябрь 2013 года. Из них 492 (0.17%) являются мошенническими. Все признаки, кроме суммы и времени, являются результатом PCA-преобразования исходных данных в целях обеспечения конфиденциальности. Высокий коэффициент несбалансированности (577:1) делает данный набор классическим тестом для методов работы с дисбалансом.

3.2.2 IEEE-CIS Fraud Detection

Данный набор данных предоставлен компанией Vesta Corporation в рамках соревнования Kaggle 2019 года и содержит 590 540 транзакций с 394 признаками, включая информацию об устройстве, браузере, временных паттернах и поведении пользователя. Высокая размерность при умеренном дисбалансе (28:1) создаёт проблему выбора признаков.

3.2.3 PaySim

PaySim - синтетический набор данных, сгенерированный на основе реальных мобильных транзакций из африканского банка. Содержит 6.3 млн транзакций с 8 признаками, из которых 0.13% являются мошенническими. Крайне высокий дисбаланс (770:1) и малое число признаков делают данный набор достаточно сложным для обработки.

3.2.4 Yelp Reviews

Набор содержит 67 395 отзывов о ресторанах с флагами мошенничества (14.5% помечены как фейковые). Помимо текстовых признаков, включает метаданные: дата написания, активность пользователя, рейтинг. Наличие слабой графовой структуры (пользователи, пишущие об одном заведении) позволяет тестировать гибридные подходы.

3.2.5 Amazon Reviews

Набор Amazon Reviews представляет собой мульти-реляционный граф, извлечённый из отзывов на товары интернет-магазина Amazon в категориях «Часы», «Видеоигры» и «Обувь». Всего датасет содержит 11 944 805 отзывов, из которых 8% помечены как фейковые. Каждый отзыв описан 35 признаками, включая текстовую мета-информацию, рейтинг, дату написания и активность пользователя. Наличие трёх типов связей (пользователь—продукт, пользователь—пользователь, продукт—продукт) позволяет тестировать графовые нейронные

сети в условиях высокомасштабных гетерогенных графов. Набор закрепился как один из классических датасетов для GNN-моделей в задачах детекции фейковых отзывов.

3.2.6 AIZBank

AIZBank — предобработанный датасет, созданный в 2025 году на основе агрегации нескольких открытых источников. Он предназначен для прогнозирования мошеннических транзакций в системах электронных платежей. Всего набор содержит 45 211 записей, из которых около 11,7% (5 290) отмечены как мошеннические. Низкий дисбаланс (8,5:1). Этот набор удобным для быстрого тестирования базовых моделей и отработки методов борьбы с неравномерным распределением классов.

3.2.7 Elliptic (Bitcoin)

Elliptic — крупнейший общедоступный графовый датасет Bitcoin-транзакций, созданный в 2019 году аналитической компанией Elliptic совместно с MIT. Содержит 203 769 транзакций (узлов) и 234 355 связей (направленных рёбер) между ними. Каждый узел описан 166 признаками (94 локальных + 72 агрегированных от соседей). Известны метки для 46 564 транзакций: 4 545 (9.8% из известных) идентифицированы как нелегальные, остальные — легальные. Это единственный в данном исследовании набор данных с реальной сложной графовой структурой.

3.2.8 Click Fraud (TalkingData AdTracking Fraud Detection)

Данные предоставлены компанией TalkingData — крупнейшим независимым оператором big data в Китае, обрабатывающим свыше 70% активных мобильных устройств в стране. В рамках соревнования Kaggle компания выпустила датасет, содержащий 200 миллионов записей о кликах по мобильной рекламе за 4 дня. Целевая переменная `is_attributed` указывает, привёл ли клик к установке приложения; в среднем только 0,2–0,3% кликов заканчиваются загрузкой, что создаёт крайне высокий дисбаланс (300:1). Каждый объект описывается 9 закодированными признаками. Огромный объём данных и сильная несбалансированность делают этот набор подходящим для проверки масштабируемости ансамблевых методов и эффективности техник борьбы с дисбалансом на реальных логах интернет-рекламы.

3.2.9 Social Honeypot Dataset

Набор включает 22 223 спамеров и 19 276 добросовестных пользователей. Это соотношение даёт почти равные классы (1:1,15), что значительно упрощает обучение моделей в сравнении с сильно несбалансированными финансовыми данными. Каждый объект (аккаунт) описывается набором из 62 признаков, охватывающих такие поведенческие и профильные метрики, как возраст аккаунта, количество подписчиков и друзей, частота публикаций и ретвитов, использование хэштегов и упоминаний. Именно обширный набор признаков делает датасет удобным для решения задачи.

3.2.10 MGTAВ (Multi-Relational Graph-Based Twitter Account Detection)

MGTAВ — графовый бенчмарк для детекции Twitter-ботов, опубликованный в 2022 году. Содержит 10 199 аккаунтов, из которых 3 652 (35.8%) являются ботами. Каждый аккаунт описан 20 профильными признаками. Граф включает два типа рёбер: отношения подписки и отношения упоминания, что позволяет тестировать гетерогенные графовые модели. Умеренный дисбаланс (1.79:1) и наличие реальной мульти-реляционной структуры делают набор удобным для сравнения GNN-подходов в задачах детекции аккаунтов-ботов.

3.2.11 Cresci-2017 (Social Spambots Detection)

Cresci-2017 — один из наиболее широко используемых эталонных наборов данных для детекции Twitter-ботов, опубликованный в 2017 году. Содержит 14 368 аккаунтов, из которых около 57% составляют три категории social spambots (боты-спамеры, маскирующиеся под людей), а 43% — верифицированные реальные пользователи. Каждый аккаунт описан 19 признаками профиля и поведения (число твитов, подписчиков, дата регистрации и др.). Датасет примечателен тем, что содержит несколько поколений ботов, сложных для обнаружения классическими методами, что обусловило его широкое применение в качестве сложного теста для детекторов ботов.

3.2.12 Midterm-2018 (User Objects Dataset)

Набор данных midterm-2018 содержит профильную информацию о 75 896 пользователях Twitter, собранную в период промежуточных выборов в США 2018 года. Каждый объект описывается 19 признаками, включая метаданные аккаунта: дату регистрации, количество подписчиков и друзей, число твитов и отметок «Нравится», статус верификации, географическую привязку, язык интерфейса и т.д. Данные внутри датасета были размече-

ны с использованием комбинации автоматических и ручных методов. Доля мошеннических ботов и легитимных аккаунтов в наборе оценивается как 16% людей против 84% ботов, что соответствует коэффициенту несбалансированности примерно 5,25:1. Таким образом, набор является несбалансированным, но не в такой крайней степени, как финансовые датасеты.

3.3 Мета-признаки наборов данных

Для мета-анализа, целью которого является выявление зависимости между свойствами данных и эффективностью алгоритмов, для каждого набора данных были вычислены количественные мета-признаки (таблица 3.2). Эти признаки отражают ключевые характеристики, влияющие на сложность задачи и выбор подходящего метода машинного обучения.

Таблица 3.2: Мета-признаки наборов данных для мета-анализа

Набор данных	$\log_{10}(N)$	$\log_{10}(\text{IR})$	d	G	$\bar{\text{deg}}$	CC
Credit Card Fraud	5.45	2.76	30	0	—	—
IEEE-CIS	5.77	1.44	393	0	—	—
PaySim	6.80	2.89	10	0	—	—
AIZBank	4.66	0.88	17	0	—	—
Elliptic (Bitcoin)	4.67	−0.97	168	1	2.30	0.014
Amazon Reviews	4.08	1.13	25	1	174.78	0.661
Yelp Reviews	4.66	0.77	32	1	4.14	0.658
Click Fraud	5.00	2.64	7	0	—	—
Social HoneyPot	4.62	−0.06	6	0	—	—
MGTAB	4.01	0.43	788	1	179.05	0.222
Cresci-2017	3.79	0.12	21	0	—	—
Midterm-2018	4.70	−0.72	19	0	—	—

G — наличие графовой структуры (0/1); $\bar{\text{deg}}$ — средняя степень узла;

CC — средний коэффициент кластеризации; «—» — значение неприменимо или недоступно.

3.3.1 Объём выборки ($\log_{10}(N)$)

Объём выборки варьируется от нескольких тысяч (Cresci-2017, 6105 объектов) до миллионов записей (PaySim, 6,36 млн). Логарифмическое преобразование применено для приведения широкого диапазона значений к сопоставимому масштабу. Ожидается, что методы глубокого обучения (MLP, VAE, GraphSAGE) требуют большего объёма данных для эффективного обучения, в то время как ансамблевые методы (Random Forest, XGBoost) демонстрируют стабильные результаты даже на выборках среднего размера.

3.3.2 Степень несбалансированности классов ($\log_{10}(\mathbf{IR})$)

Коэффициент несбалансированности $\mathbf{IR}$ определяется как отношение числа объектов отрицательного класса (нормальные транзакции, легитимные пользователи) к числу объектов положительного класса (мошеннические действия). Логарифмическая шкала позволяет адекватно сравнивать датасеты с экстремальным дисбалансом.

Крайне высокий дисбаланс ($\mathbf{IR} > 100$, $\log_{10}(\mathbf{IR}) > 2$): Credit Card Fraud ($\mathbf{IR} = 577,9$), PaySim ($\mathbf{IR} = 773,7$), Click Fraud ($\mathbf{IR} = 439,5$). В таких условиях модель, предсказывающая всегда «норму», будет иметь точность выше 99%, но не обнаружит ни одного мошенничества. Это требует применения специальных техник: взвешивания классов, оверсэмплинга или использования аномально-ориентированных методов (VAE).

Умеренный дисбаланс ($10 < \mathbf{IR} < 100$, $1 < \log_{10}(\mathbf{IR}) < 2$): IEEE-CIS ($\mathbf{IR} = 27,6$), Amazon Reviews ($\mathbf{IR} = 13,5$). Задача остаётся несбалансированной, но стандартные методы с регулировкой порога классификации или взвешиванием классов часто дают приемлемые результаты.

Низкий дисбаланс ($\mathbf{IR} < 10$, $\log_{10}(\mathbf{IR}) < 1$): AIZBank ($\mathbf{IR} = 7,5$), Yelp Reviews ($\mathbf{IR} = 5,9$), MGTA ($\mathbf{IR} = 1,04$), Cresci-2017 ($\mathbf{IR} = 1,32$). Доля мошеннических объектов составляет от 10% до 50%, что упрощает обучение и позволяет использовать стандартные метрики, такие как ассигасу, с определённой осторожностью.

Обратный дисбаланс ($\mathbf{IR} < 1$, $\log_{10}(\mathbf{IR}) < 0$): Elliptic ($\mathbf{IR} = 0,11$), Social Honeypot ($\mathbf{IR} = 0,87$), Midterm-2018 ($\mathbf{IR} = 0,19$). В этих датасетах мошеннический класс (боты, нелегальные транзакции) является доминирующим. Например, в Midterm-2018 боты составляют 84% выборки, в Elliptic — 90%. Это менее типичная ситуация для задач обнаружения мошенничества, однако может встречаться на некоторых сервисах, особенно при кибер-атаках. Поэтому такой вариант также требует учёта при обучении (например, обратного взвешивания классов или использования метрик, ориентированных на класс большинства).

3.3.3 Число признаков (d)

Размерность признакового пространства варьируется от 6 (Social Honeypot) до 788 (MGTA). Высокая размерность создаёт проблему «проклятия размерности» и требует регуляризации или отбора признаков. Низкая размерность (Click Fraud — 7 признаков, Social Honeypot — 6 признаков) упрощает модель, но может ограничивать её выразительную способность. Большинство датасетов имеют умеренное число признаков (от 10 до 30), что является типичным для задач обнаружения мошенничества.

3.3.4 Наличие графовой структуры (G)

Флаг $G = 1$ означает, что датасет содержит связи между объектами и может использоваться для обучения графовых нейронных сетей. Графовые структуры присутствуют в Elliptic (транзакции Bitcoin), Amazon Reviews (связи между пользователями и товарами), Yelp Reviews и MGTAВ (подписки и упоминания в социальной сети). Отсутствие графа ($G = 0$) не позволяет применять GNN-методы напрямую. Искусственное построение графа по демографическим или иным немотивированным признакам, а также самостоятельное назначение весов рёбрам в данной работе не применяется. Такие подходы не отражают реальную структуру мошеннических взаимодействий, вносят ложные зависимости, снижают обобщающую способность моделей и нарушают воспроизводимость эксперимента. Таким образом, используются только исходные графовые структуры, предоставленные авторами датасетов.

3.3.5 Средняя степень узла ($\bar{\text{deg}}$) и коэффициент кластеризации (CC)

Эти метрики описывают плотность и структуру графа, что критически важно для понимания поведения графовых алгоритмов. Они вычислены только для датасетов с графовой структурой.

Amazon Reviews ($\bar{\text{deg}} = 174, 78$, **CC = 0,661**):

Очень высокая средняя степень объясняется способом построения графа. Использовался граф типа «пользователь-пользователь» на основе общих товаров. Популярные товары на Amazon собирают сотни и тысячи отзывов, создавая между соответствующими пользователями полносвязные подграфы (клики), высокий коэффициент кластеризации (0,661) подтверждает наличие таких плотных сообществ. Для графовых моделей это означает, что информация распространяется очень быстро (за 1–2 шага агрегирования), и узлы имеют большое количество соседей, чьи признаки усредняются.

Yelp Reviews ($\bar{\text{deg}} = 4, 14$, **CC = 0,658**): Граф также построен по принципу общих заведений, но отзывов на одно заведение значительно меньше, чем на товары Amazon. Средняя степень низкая, но коэффициент кластеризации остаётся высоким (0,658), что указывает на наличие множества небольших плотных кластеров (группы пользователей, оставивших отзывы на одно и то же заведение).

Elliptic ($\bar{\text{deg}} = 2, 30$, **CC = 0,014**): Транзакционный граф Bitcoin, где узлы — транзакции, а рёбра — потоки средств. Это естественный разреженный граф с очень низкой кластеризацией, так как транзакции редко образуют треугольные структуры (средства редко возвращаются к отправителю через промежуточные транзакции). Низкая степень упрощает

агрегирование информации и делает графовые методы вычислительно эффективными.

MGTAB ($\bar{deg} = 179,05$, **CC** = **0,222**): Граф социальной сети (Twitter) на основе подписок и упоминаний. В отличие от типично разреженных социальных графов, здесь высокая средняя степень из-за множества подписок на популярных пользователей. Коэффициент кластеризации умеренный (0,222), что указывает на наличие некоторого количества треугольников, но граф не является сверхплотным.




Рис. 3.1: Структура связей в графовых датасетах на выборке

3.3.6 Интерпретация для мета-анализа

Совокупность мета-признаков позволяет сформулировать гипотезы о том, какие алгоритмы будут эффективны для каждого типа данных.

Для датасетов с экстремально высоким дисбалансом и табличной структурой (Credit Card Fraud, PaySim, Click Fraud) наилучшие результаты должен показывать XGBoost со

взвешиванием классов, а VAE может быть полезен в полуконтролируемом режиме. Высоко-размерный IEEE-CIS (393 признака) требует регуляризации, где XGBoost и Random Forest ожидаемо будут превосходить линейные модели. В графовых датасетах с низким дисбалансом эффективен GraphSAGE: на плотном графе Amazon с очень высокой степенью узлов достаточно одного слоя агрегации, на Yelp с разреженными кластерами — стандартная архитектура. Для транзакционного графа Elliptic с разреженной структурой и обратным дисбалансом (90% нелегальных транзакций) GraphSAGE с балансировкой классов также должен дать прирост. Сбалансированные и маломерные Social Honeypot и AIZBank, скорее всего, не требуют сложных моделей — логистическая регрессия или Random Forest будут достаточны. Датасет MGTAВ, в отличие от предыдущего описания, содержит как признаки узлов (788 числовых характеристик), так и граф подписок и упоминаний, поэтому здесь применимы как табличные методы, так и GraphSAGE. Midterm-2018 с обратным дисбалансом (84% ботов) и Cresci-2017 со сбалансированными классами служат тестами устойчивости моделей к разным соотношениям классов. Эти гипотезы проверяются в экспериментальной части работы.

3.4 Предобработка данных

Для обеспечения корректности сравнения результатов на разных наборах данных применяется единая схема предобработки, реализованная в виде модуля на языке Python. Все операции настраиваются исключительно на обучающей выборке и затем применяются к валидационной и тестовой, что исключает утечку информации. Ниже последовательно описаны основные этапы.

3.4.1 Удаление малополезных признаков

На первом этапе из набора удаляются признаки, доля пропущенных значений в которых превышает 80%. Такие признаки не несут достаточной информации и могут внести шум в модель. Порог 80% выбран эмпирически как компромисс между сохранением данных и фильтрацией слишком разреженных столбцов.

3.4.2 Заполнение пропусков

После удаления высокопропущенных признаков оставшиеся пропуски заполняются:

- для **числовых** признаков - медианой, вычисленной по обучающей выборке. Медиана устойчива к выбросам, что важно для финансовых данных.

- для **категориальных** признаков - модой (наиболее частым значением) на обучающей выборке. Если мода не определена (все значения уникальны), используется специальный токен 'missing'.

3.4.3 Кодирование категориальных признаков

В анализируемых датасетах большинство признаков были числовыми. Однако в некоторых наборах (IEEE-CIS, PaySim, AIZBank, Midterm-2018) присутствовали категориальные столбцы, такие как тип транзакции, email-домен, семейное положение, язык профиля и т.п. Категориальные признаки преобразуются в числовой формат с использованием комбинированного подхода.

Для категориальных признаков с количеством уникальных значений меньше порога (в реализации используется `cat_threshold = 5`), применяется *one-hot кодирование* с использованием `OneHotEncoder`. Это позволяет представить каждую категорию в виде бинарного вектора, не внося ложного порядкового отношения.

Для признаков с большим числом уникальных значений применялось *label encoding* с помощью `LabelEncoder`, которое заменяет каждую категорию уникальным целым числом. Такой подход допустим для ансамблевых методов, устойчивых к немонотонным зависимостям, и позволяет избежать катастрофического роста размерности при one-hot кодировании.

Временные метки (столбцы, содержащие дату и время) исключались из обучающей выборки, поскольку абсолютное время не является информативным признаком для обнаружения мошенничества.

Все кодировщики настраивались исключительно на обучающей выборке и затем применялись к валидационной и тестовой для предотвращения утечки информации. Целевое кодирование (target encoding) не использовалось, так как оно могло внести утечку меток и привести к переобучению.

3.4.4 Масштабирование числовых признаков

Все числовые признаки масштабируются с помощью робастного масштабировщика (`RobustScaler`) из библиотеки `scikit-learn`:

$$\tilde{x}_j = \frac{x_j - Q_{0.5}(x_j)}{Q_{0.75}(x_j) - Q_{0.25}(x_j)}, \quad (7)$$

где Q_p — p -квантиль, вычисленный по обучающей выборке. Данный метод устойчив к выбросам, что особенно важно для финансовых датасетов, где могут встречаться аномально

большие суммы или количества. Признаки, полученные в результате one-hot кодирования, не масштабируются, поскольку они уже находятся в диапазоне $[0, 1]$.

3.4.5 Обработка выбросов

Для дополнительного снижения влияния экстремальных значений числовые признаки, выходящие за пределы интервала $[Q_{0.01}, Q_{0.99}]$, где $Q_{0.01}$ и $Q_{0.99}$ - 1-й и 99-й процентиля, вычисленные по обучающей выборке, подвергаются ограничению. Все значения за пределами этого диапазона заменяются на соответствующую границу. Такая обработка предотвращает доминирование редких выбросов при обучении моделей, чувствительных к масштабу.

3.4.6 Построение графов

Для датасетов, обладающих графовой структурой (Elliptic, Amazon, Yelp и MGTAB), граф строится в соответствии с доменной логикой. Реализована функция `load_graph(dataset_name)`, которая возвращает объект графа в формате PyTorch Geometric (`torch_geometric.data.Data`), содержащий:

- **Матрицу признаков узлов (X)**, где строки соответствуют узлам, столбцы — числовым признакам, полученным после предобработки (кодирование, масштабирование).
- **Рёбра ($edge_index$)** — тензор размером $2 \times E$, где E — количество связей.
- **Целевые метки (y)** для узлов, участвующих в обучении.

Конкретные источники данных:

- **Elliptic**: файлы `elliptic_txs_features.csv`, `elliptic_txs_edgelist.csv` и `elliptic_txs_labels.csv`
- **Amazon Reviews**: признаки берутся из `Amazon_full.csv` (последний столбец - метка), рёбра - из файла `Amazon_net_uvu_edges.csv` (связи пользователь-пользователь)
- **Yelp Reviews**: признаки и метки из `YelpChi_full.csv`, рёбра из `YelpChi_net_rur_edges.csv`
- **MGTAB**: признаки из `features.csv`, рёбра из `edge_index.csv`, метки из `labels_bot.csv`

Для датасетов, не имеющих графовой структуры, искусственное построение графа не выполнялось, поскольку произвольное конструирование рёбер (например, на основе сходства признаков, демографических характеристик) не отражает реальных мошеннических связей, может внести ложные зависимости, привести к переобучению и нарушить воспроизводимость результатов, а также ухудшить обобщающую способность моделей.

3.4.7 Итоговая схема предобработки

Все описанные операции реализованы в виде набора функций: `preprocess_data` для табличных данных, а для графовых датасетов — отдельные загрузчики, которые непосредственно возвращают матрицу признаков узлов, тензор рёбер и целевые метки. Параметры заполнения пропусков и масштабирования вычисляются исключительно на обучающей выборке и затем применяются к валидационной и тестовой, что гарантирует корректность кросс-валидации.

4 Алгоритмы

В данном разделе описаны восемь алгоритмов, реализованных в рамках исследования.

4.1 Логистическая регрессия (LR)

Логистическая регрессия служит базовым методом (*baseline*). Вероятность принадлежности к положительному классу моделируется через сигмоидальную функцию:

$$P(y = 1 \mid \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^\top \mathbf{x} + b)}}, \quad (8)$$

где $\mathbf{w} \in \mathbb{R}^d$ — вектор весов, b — смещение. Обучение выполняется минимизацией бинарной кросс-энтропии с L_2 -регуляризацией:

$$\mathcal{L}_{\text{LR}} = -\frac{1}{n} \sum_{i=1}^n [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)] + \frac{1}{2C} \|\mathbf{w}\|_2^2, \quad (9)$$

где $C > 0$ — параметр, обратный силе регуляризации.

Гиперпараметры и настройка. Значение C выбирается по сетке $\{0.01, 0.1, 1, 10, 100\}$ по AUPRC на валидационной выборке. Оптимизатор — L-BFGS, максимальное число итераций — 1000.

Работа с дисбалансом. Применяется взвешивание классов (`class_weight='balanced'`), при котором вес положительного класса устанавливается обратно пропорционально его частоте:

$$w_+ = \frac{N_-}{N_+} = \text{IR}, \quad (10)$$

где N_- и N_+ — количество объектов нормального и мошеннического классов соответственно, а IR — коэффициент несбалансированности.

Реализация: `scikit-learn` [29], `LogisticRegression(solver='lbfgs', max_iter=1000)`.

4.2 Случайный лес (RF)

Случайный лес [4] строит ансамбль из $B = 500$ деревьев решений, каждое из которых обучается на случайной bootstrap-подвыборке. Предсказание ансамбля — усредненная вероятность:

$$\hat{p}_{\text{RF}}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \hat{p}_b(\mathbf{x}), \quad (11)$$

где $\hat{p}_b(\mathbf{x})$ — вероятность, предсказанная b -м деревом.

Гиперпараметры и настройка. Количество деревьев в финальной модели $B = 500$. Для ускорения обучения задействуются все доступные ядра процессора (`n_jobs=-1`). Поиск оптимальных гиперпараметров выполняется случайным поиском (10 итераций) по метрике AUPRC на валидационной выборке. Перебираются следующие значения:

- `max_depth` — максимальная глубина дерева: $\{10, 20, 30, \text{None}\}$;
- `min_samples_leaf` — минимальное число объектов в листе: $\{1, 3, 5, 10\}$;
- `max_features` — число признаков, рассматриваемое при каждом разбиении: $\{\sqrt{d}, \log_2 d, \text{None}\}$;

Для ускорения подбора гиперпараметров на больших датасетах (более 60 тысяч объектов) процесс настройки выполняется на стратифицированной подвыборке размером 60 000 объектов. После нахождения лучшей комбинации финальная модель обучается на всех доступных обучающих данных с $B = 500$ деревьями.

Работа с дисбалансом. Используется взвешивание `class_weight='balanced_subsample'`, при котором веса классов пересчитываются независимо для каждого дерева по его bootstrap-выборке, что устойчивее, чем глобальное взвешивание при экстремальном дисбалансе.

Реализация: `scikit-learn` [29], `RandomForestClassifier(n_estimators=500, n_jobs=-1)`

4.3 XGBoost

XGBoost [7] реализует градиентный бустинг на деревьях. Ансамбль строится последовательно: каждое следующее дерево h_t аппроксимирует отрицательный градиент функции потерь предыдущего ансамбля F_{t-1} :

$$F_t(\mathbf{x}) = F_{t-1}(\mathbf{x}) + \eta \cdot h_t(\mathbf{x}), \quad (12)$$

где η — скорость обучения (*learning rate*).

Гиперпараметры и настройка. Поиск оптимальных гиперпараметров выполняется случайным поиском (10 итераций) по метрике AUPRC на валидационной выборке. Перебираются следующие значения:

- скорость обучения $\eta \in \{0.01, 0.05, 0.1, 0.2, 0.3\}$;

- число деревьев: {200, 400, 600, 800};
- максимальная глубина: {3, 5, 7, 9};
- λ (L2-регуляризация): {0.1, 1, 10};
- `subsample`, `colsample_bytree`: {0.6, 0.8, 1.0}.

Для ускорения подбора гиперпараметров на больших датасетах (более 60 тысяч объектов) настройка выполняется на стратифицированной подвыборке размером 60 000 объектов. Применяется ранняя остановка по метрике `aucpr` на валидационной выборке (`patience` = 20). Метод разбиения — `hist` (гистограммный алгоритм).

Работа с дисбалансом. Устанавливается параметр:

$$\text{scale_pos_weight} = \min\left(\frac{N_-}{N_+}, 500\right), \quad (13)$$

где ограничение сверху значением 500 предотвращает численную нестабильность при крайне высоком дисбалансе.

Реализация: `xgboost` [7], `XGBClassifier(tree_method='hist', eval_metric='aucpr')`.

4.4 Многослойный перцептрон (MLP)

MLP является базовым методом глубинного обучения. Каждый слой выполняет линейное преобразование с последующей нелинейной активацией:

$$\mathbf{h}^{(l)} = \text{ReLU}(\text{BN}(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)})), \quad (14)$$

где $\text{BN}(\cdot)$ — Batch Normalization, $\text{ReLU}(x) = \max(0, x)$. Используется четырёхслойная архитектура:

$$d \xrightarrow{\text{BN}} 256 \xrightarrow{\text{BN, ReLU, Drop}(0.3)} 128 \xrightarrow{\text{BN, ReLU, Drop}(0.3)} 64 \xrightarrow{\text{ReLU}} 1, \quad (15)$$

где $\text{Drop}(p)$ — дропаут с вероятностью $p = 0.3$.

Гиперпараметры и настройка. Архитектура фиксирована. Для ускорения обучения на больших датасетах используется стратифицированная подвыборка размером 60 000 объектов. Обучение выполняется оптимизатором Adam ($\text{lr} = 10^{-3}$, $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\text{weight decay} = 10^{-5}$) с планировщиком `ReduceLROnPlateau` (`factor` = 0.5, `patience` = 7). Размер батча — 512. Максимальное число эпох — 100; ранняя остановка по AUPRC на валидационной выборке, `patience` = 15.

Работа с дисбалансом. Применяется взвешенная бинарная кросс-энтропия:

$$\mathcal{L}_{\text{MLP}} = -\frac{1}{n} \sum_{i=1}^n [w_+ y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)], \quad w_+ = \frac{N_-}{N_+}. \quad (16)$$

Реализация: PyTorch [28].

4.5 Вариационный автокодировщик (VAE)

VAE [25] применяется в полуконтролируемом режиме: модель обучается исключительно на нормальных (немошеннических) объектах, а аномальный счёт вычисляется по ошибке восстановления на тестовой выборке.

Кодировщик $q_\phi(\mathbf{z} \mid \mathbf{x})$ отображает входной объект в параметры гауссовского распределения в латентном пространстве:

$$d \xrightarrow{\text{ReLU}} 128 \xrightarrow{\text{ReLU}} 64 \longrightarrow \boldsymbol{\mu} \in \mathbb{R}^{32}, \quad \log \boldsymbol{\sigma}^2 \in \mathbb{R}^{32}. \quad (17)$$

Декодировщик $p_\theta(\mathbf{x} \mid \mathbf{z})$ имеет зеркальную структуру:

$$32 \xrightarrow{\text{ReLU}} 64 \xrightarrow{\text{ReLU}} 128 \longrightarrow d. \quad (18)$$

Гиперпараметры и настройка. Архитектура фиксирована. Для ускорения обучения на больших датасетах используется случайная подвыборка размером 60 000 объектов как для обучающей, так и для валидационной выборки. Обучение выполняется оптимизатором Adam ($\text{lr} = 10^{-3}$), максимальное число эпох — 80, ранняя остановка по ошибке восстановления на валидационной выборке, $\text{patience} = 10$. Параметры модели обучаются максимизацией β -ELBO:

$$\mathcal{L}_{\text{VAE}} = \underbrace{\mathbb{E}_{q_\phi}[\log p_\theta(\mathbf{x} \mid \mathbf{z})]}_{\text{ошибка восстановления}} - \beta \cdot \underbrace{D_{\text{KL}}(q_\phi(\mathbf{z} \mid \mathbf{x}) \parallel \mathcal{N}(\mathbf{0}, \mathbf{I}))}_{\text{регуляризатор}}, \quad \beta = 0.5. \quad (19)$$

Аномальный счёт объекта $\mathbf{x}$:

$$s(\mathbf{x}) = \|\mathbf{x} - \hat{\mathbf{x}}\|_2^2 + 0.5 \cdot D_{\text{KL}}(q_\phi(\mathbf{z} \mid \mathbf{x}) \parallel \mathcal{N}(\mathbf{0}, \mathbf{I})). \quad (20)$$

Мошеннические объекты, как правило, плохо восстанавливаются моделью, обученной на нормальных данных, что приводит к повышенному значению $s(\mathbf{x})$.

Реализация: PyTorch [28].

4.6 Графовая сверточная сеть (GCN)

GCN (Graph Convolutional Network) [26] является одной из первых и наиболее фундаментальных архитектур графовых нейронных сетей. В отличие от GraphSAGE, GCN работает в *транздуктивном* режиме: граф должен быть полностью известен на этапе обучения, а свёртка определяется в спектральной области через нормализованную матрицу смежности. Обновление признаков узла на слое k выполняется по формуле:

$$\mathbf{H}^{(k)} = \sigma\left(\tilde{\mathbf{D}}^{-1/2} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-1/2} \mathbf{H}^{(k-1)} \mathbf{W}^{(k)}\right), \quad (21)$$

где $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}$ — матрица смежности с добавленными петлями, $\tilde{\mathbf{D}}$ — диагональная матрица степеней, $\mathbf{W}^{(k)}$ — обучаемые веса, σ — функция активации (ReLU).

Архитектура и настройка. В работе используется двухслойная GCN:

- первый свёрточный слой: $d \rightarrow 256$;
- второй свёрточный слой: $256 \rightarrow 128$;
- после каждого свёрточного слоя — Batch Normalization и ReLU;
- финальный линейный слой: $128 \rightarrow 1$.

Максимальное число эпох — 100, ранняя остановка по AUPRC на валидационной выборке с patience = 15.

Работа с дисбалансом. Функция потерь — взвешенная бинарная кросс-энтропия с весом положительного класса $w_+ = \min(\text{IR}, 500)$. Оптимизатор — Adam (lr = $5 \cdot 10^{-3}$, weight decay = $5 \cdot 10^{-5}$) с планировщиком CosineAnnealingLR.

Реализация: PyTorch Geometric [13], GCNConv.

4.7 Graph Attention Network (GAT)

GAT (Graph Attention Network) [32] вводит механизм внимания для взвешенной агрегации информации от соседей. В отличие от GCN, где веса соседей фиксированы (нормализованные степени), GAT вычисляет динамические коэффициенты внимания α_{uv} между узлами u и v :

$$\alpha_{uv} = \frac{\exp(\text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_u \parallel \mathbf{W}\mathbf{h}_v]))}{\sum_{k \in \mathcal{N}(u) \cup \{u\}} \exp(\text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_u \parallel \mathbf{W}\mathbf{h}_k]))}, \quad (22)$$

где $\mathcal{N}(u)$ — множество соседей узла u , $\mathbf{W}$ — матрица линейного преобразования, $\mathbf{a}$ — вектор параметров внимания. Итоговый эмбединг узла получается как взвешенное средство преобразованных признаков соседей, усреднённое по K независимым головам внимания (multi-head attention).

Архитектура и настройка. Используется двухслойная GAT:

- первый слой: multi-head attention с $K = 8$ головами. Размерность выходного представления каждой головы — $256/8 = 32$, что после конкатенации даёт вектор размерности 256;
- второй слой: single-head attention с выходной размерностью 128;
- после каждого слоя — Batch Normalization, ReLU и Dropout ($p = 0.3$);
- финальный линейный слой: $128 \rightarrow 1$.

Максимальное число эпох — 100, ранняя остановка по AUPRC на валидационной выборке с patience = 15.

Работа с дисбалансом. Функция потерь — взвешенная бинарная кросс-энтропия с весом положительного класса $w_+ = \min(\text{IR}, 500)$. Оптимизатор — Adam ($\text{lr} = 5 \cdot 10^{-3}$, weight decay = $5 \cdot 10^{-5}$) с планировщиком CosineAnnealingLR.

Реализация: PyTorch Geometric [13], GATConv.

4.8 GraphSAGE

GraphSAGE [17] применяется к наборам данных с графовой структурой (Elliptic, Amazon, Yelp, MGTAВ). В отличие от GCN, GraphSAGE работает индуктивно — он не требует, чтобы граф был известен целиком на этапе обучения, и обобщается на новые узлы без дополнительного переобучения. Для каждого узла v его эмбединг вычисляется итеративным агрегированием признаков случайно выбранных соседей:

$$\mathbf{h}_{\mathcal{S}_k(v)}^{(k-1)} = \text{MEAN}(\{\mathbf{h}_u^{(k-1)} : u \in \mathcal{S}_k(v)\}), \quad (23)$$

$$\mathbf{h}_v^{(k)} = \sigma\left(\mathbf{W}^{(k)} \left[\mathbf{h}_v^{(k-1)} \parallel \mathbf{h}_{\mathcal{S}_k(v)}^{(k-1)} \right]\right), \quad (24)$$

где $\mathcal{S}_k(v)$ — случайная выборка соседей узла v на k -м шаге, $\parallel \cdot \parallel$ — конкатенация, σ — функция активации (ReLU).

Архитектура и настройка. Используется двухслойная архитектура: первый слой выбирает $|\mathcal{S}_1(v)| = 25$ соседей, второй — $|\mathcal{S}_2(v)| = 10$. Скрытые размерности: 256 и 128 соответственно. После каждого слоя агрегирования добавляется Batch Normalization.

Максимальное число эпох — 100, ранняя остановка по AUPRC на валидационной выборке с $\text{patience} = 15$.

Работа с дисбалансом. Функция потерь — взвешенная бинарная кросс-энтропия с весом положительного класса $w_+ = \min(\text{IR}, 500)$. Оптимизатор — Adam ($\text{lr} = 5 \cdot 10^{-3}$, $\text{weight decay} = 5 \cdot 10^{-5}$) с планировщиком CosineAnnealingLR.

Реализация: PyTorch Geometric [13], SAGEConv($\text{aggr}=\text{'mean'}$).

4.9 Сводная таблица гиперпараметров

В таблице 4.1 приведены ключевые гиперпараметры всех алгоритмов.

Таблица 4.1: Гиперпараметры алгоритмов

Алгоритм	Настройка	Метрика	Дисбаланс
LR	Grid Search (C : 0.01–100)	AUPRC	<code>class_weight='balanced'</code>
RF	Random Search (10 итераций)	AUPRC	<code>balanced_subsample</code>
XGBoost	Random Search (10 итераций)	AUPRC	<code>scale_pos_weight = IR</code>
MLP	Фиксированная архитектура (256-128-64)	AUPRC	Взвешенная BCE
VAE	Фиксированная архитектура (128-64-32), $\beta = 0.5$	Recon. loss	Только нормальный класс
GraphSAGE	Фиксированная (2 слоя, 256-128, MEAN)	AUPRC	Взвешенная BCE
GCN	Фиксированная (2 слоя, 256-128)	AUPRC	Взвешенная BCE
GAT	Фиксированная (2 слоя, heads=8)	AUPRC	Взвешенная BCE

5 Дизайн экспериментов

5.1 Протокол оценки

5.1.1 Разбиение данных

Для обеспечения корректности сравнения все модели обучаются на одинаково предобработанных данных (раздел 3) и оцениваются на единой системе разбиений, учитывающей природу каждого набора данных. Стратегия разбиения выбирается индивидуально:

- Для **табличных датасетов** (Credit Card Fraud, IEEE-CIS, PaySim, AIZBank, Social Honeypot, Click Fraud, Cresci-2017, Midterm-2018, Pronbots-2019) применяется *стратифицированное случайное разбиение* с пропорциями $\text{train} : \text{val} : \text{test} = 70 : 15 : 15$ с сохранением распределения целевого класса.
- Для **графовых датасетов** (Elliptic, Amazon Reviews, Yelp Reviews, MGTAB) используется *трандуктивное разбиение узлов*: случайным образом выбираются узлы для обучения (70%), валидации (15%) и тестирования (15%) при сохранении всей структуры рёбер графа. Это позволяет модели использовать информацию о связях между узлами разных выборок.

Все модели настраиваются по единой метрике — AUPRC на валидационной выборке. Для каждого алгоритма зафиксированы: архитектура или пространство гиперпараметров, метод их подбора, стратегия работы с несбалансированными данными и библиотека реализации.

5.1.2 Повторяемость

Для учёта случайности каждый эксперимент повторяется с $K = 5$ различными начальными значениями генератора случайных чисел: $\{42, 43, 44, 45, 46\}$. Итоговые метрики — среднее и стандартное отклонение по K запускам.

5.2 Метрики оценки

Поскольку все исследуемые наборы данных несбалансированы, применяется набор метрик, нечувствительных к классовому дисбалансу.

5.2.1 AUPRC (площадь под PR-кривой)

PR-кривая строится по парам (Precision, Recall) для всех порогов классификации $t \in [0, 1]$:

$$\text{Precision}(t) = \frac{\text{TP}(t)}{\text{TP}(t) + \text{FP}(t)}, \quad \text{Recall}(t) = \frac{\text{TP}(t)}{\text{TP}(t) + \text{FN}(t)}. \quad (25)$$

AUPRC — площадь под этой кривой (метрика основная):

$$\text{AUPRC} = \int_0^1 \text{Precision}(\text{Recall}) d(\text{Recall}). \quad (26)$$

В отличие от AUROC, AUPRC не зависит от числа истинно отрицательных объектов и более информативна при значительном дисбалансе. Базовое значение (random classifier): $\text{AUPRC}_{\text{base}} = \frac{N_+}{N_+ + N_-} = \frac{1}{1 + \text{IR}}$.

5.2.2 F1-мера

F1-мера — среднее гармоническое точности и полноты при оптимальном пороге t^* :

$$t^* = \arg \max_t F_1(t), \quad F_1(t) = \frac{2 \cdot \text{Precision}(t) \cdot \text{Recall}(t)}{\text{Precision}(t) + \text{Recall}(t)}. \quad (27)$$

Оптимальный порог определяется по валидационной выборке.

5.2.3 AUROC (площадь под ROC-кривой)

ROC-кривая строится по парам (TPR, FPR) для всех порогов классификации:

$$\text{TPR}(t) = \frac{\text{TP}(t)}{\text{TP}(t) + \text{FN}(t)} \quad (\text{Recall}), \quad \text{FPR}(t) = \frac{\text{FP}(t)}{\text{FP}(t) + \text{TN}(t)}. \quad (28)$$

AUROC — площадь под ROC-кривой. Эта метрика показывает, насколько хорошо модель ранжирует объекты: вероятность того, что случайно выбранный мошеннический объект получит более высокую оценку, чем случайно выбранный легитимный. В данном исследовании AUROC приводится как вспомогательная метрика для сравнения графовых алгоритмов.

5.2.4 Precision@K

Precision@K рассматривает K объектов с наибольшей предсказанной вероятностью мошенничества. Параметр K выбирается как ожидаемое число мошеннических объектов в

тестовой выборке:

$$K = \lceil N_{\text{test}} \cdot \frac{N_+}{N} \rceil, \quad \text{Precision@K} = \frac{1}{K} \sum_{i \in \text{TopK}} y_i. \quad (29)$$

5.3 Статистическое тестирование

Для проверки значимости различий между алгоритмами применяется критерий Вилкоксона (непараметрический парный тест) с поправкой Бонферрони на множественное тестирование. Нулевая гипотеза: медианы AUPRC двух алгоритмов одинаковы. Уровень значимости: $\alpha = 0.05$ (после поправки). Для анализа корреляций между мета-признаками и производительностью алгоритмов используется ранговый коэффициент корреляции Спирмена ρ .

5.4 Вычислительные ресурсы

Все эксперименты проводились на локальной вычислительной среде (персональный ноутбук) со следующими характеристиками:

- Операционная система: macOS;
- Процессор: Apple M4 (архитектура ARM), 10 ядер;
- Оперативная память: 16 ГБ;
- Среда выполнения: PyCharm, интерпретатор Python 3.9;
- Графический ускоритель: отсутствует, все вычисления выполнялись на CPU.

Время выполнения экспериментов варьировалось от размера датасета и сложности алгоритма. Общее время выполнения полного запуска составляло от нескольких секунд (логистическая регрессия на Credit Card Fraud) до нескольких часов (случайный лес на IEEE-CIS и MGTAB). Для ускорения вычислений на крупнейших наборах данных (PaySim: 6.3 млн объектов, IEEE-CIS: 590 тыс. объектов с 394 признаками) применялась стратифицированная подвыборка размером 60 000 объектов для этапа подбора гиперпараметров, однако финальное обучение моделей выполнялось на полных данных.

Общее время выполнения всех экспериментов для случайного леса (12 датасетов) составило 4 часа 23 минуты. Для XGBoost, MLP и графовых методов время было меньше (от нескольких минут до 2 часов на все датасеты)

6 Экспериментальные результаты

6.1 Основные результаты по AUPRC

Таблица 6.1 демонстрирует значения AUPRC для табличных методов.

XGBoost демонстрирует наилучшие результаты на большинстве датасетов.

Алгоритм занимает первое место по AUPRC на 6 из 12 датасетов: IEEE-CIS (0.805), PaySim (0.946), AIZBank (0.573), Yelp Reviews (0.853), MGTAВ (0.909) и Midterm-2018 (1.000). На Elliptic (Bitcoin) и Amazon Reviews XGBoost показывает результаты, сопоставимые с RF (0.9996 и 0.9145 соответственно).

Случайный лес (RF) лидирует на Credit Card Fraud (0.841) и Amazon Reviews (0.909), а также демонстрирует наилучший результат на Cresci-2017 (0.9995). Особенно сильное преимущество RF наблюдается на Click Fraud (0.339 против 0.307 у XGBoost), где случайный лес показывает заметно лучшие результаты. Также хочется отметить, что при работе в компании именно случайный лес максимально соответствовал антифродным требованиям для наших практических задач. Это обусловлено его интерпретируемостью и устойчивостью к выбросам.

Логистическая регрессия (LR) значительно уступает ансамблевым методам на всех датасетах, особенно на Click Fraud (0.046) и Yelp Reviews (0.389). Единственное исключение — Midterm-2018, где LR достигает 0.999, что объясняется высокой информативностью признаков, а не качеством метода.

MLP показывает результаты, сравнимые с LR, но уступает RF и XGBoost на всех датасетах. Наибольший разрыв наблюдается на Elliptic (0.953 против 0.999 у XGBoost) и Yelp Reviews (0.653 против 0.853).

VAE как полуконтролируемый метод эффективен только на датасетах с высокой долей мошенничества (Elliptic – 0.951, Social Honeypot – 0.788, Cresci-2017 – 0.716). На сильно несбалансированных данных (Click Fraud, IEEE-CIS, PaySim) его AUPRC близок к нулю.

Наиболее сложными датасетами оказались Click Fraud (AUPRC лучшего метода – 0.339) и IEEE-CIS (0.805). Напротив, на Midterm-2018 и Cresci-2017 все методы достигают почти идеальных значений ($\text{AUPRC} > 0.96$).

Общая закономерность: ансамблевые методы (XGBoost, RF) стабильно превосходят линейные и глубокие модели на всех типах данных, особенно при высоком дисбалансе классов и сложной структуре признаков.

Таблица 6.1: Сравнение AUPRC для табличных методов

Датасет	LR	RF	XGBoost	MLP	VAE
Credit Card Fraud	0.7523 ± 0.0600	0.8406 ± 0.0304	0.8156 ± 0.0437	0.7017 ± 0.0694	0.6258 ± 0.0902
IEEE-CIS	0.4049 ± 0.0037	0.6943 ± 0.0132	0.8052 ± 0.0157	0.4106 ± 0.0052	0.1775 ± 0.1702
PaySim	0.5606 ± 0.0120	0.9088 ± 0.0136	0.9460 ± 0.0153	0.6338 ± 0.0276	0.2753 ± 0.0682
AIZBank	0.5246 ± 0.0128	0.5687 ± 0.0103	0.5733 ± 0.0170	0.5561 ± 0.0116	0.2035 ± 0.0144
Elliptic (Bitcoin)	0.9884 ± 0.0016	0.9996 ± 0.0001	0.9996 ± 0.0001	0.9531 ± 0.0019	0.9512 ± 0.0000
Amazon Reviews	0.8836 ± 0.0182	0.9086 ± 0.0231	0.9145 ± 0.0272	0.8947 ± 0.0195	0.6194 ± 0.0567
Yelp Reviews	0.3885 ± 0.0090	0.7681 ± 0.0133	0.8533 ± 0.0131	0.6532 ± 0.0111	0.2322 ± 0.0064
Click Fraud	0.0457 ± 0.0228	0.3387 ± 0.0581	0.3073 ± 0.0234	0.0609 ± 0.0129	0.0134 ± 0.0021
Social Honeypot	0.9451 ± 0.0052	0.9882 ± 0.0010	0.9884 ± 0.0009	0.9872 ± 0.0011	0.7880 ± 0.0056
MGTAB	0.8550 ± 0.0217	0.8817 ± 0.0066	0.9092 ± 0.0041	0.8773 ± 0.0130	0.3607 ± 0.0181
Cresci-2017	0.9624 ± 0.0237	0.9995 ± 0.0003	0.9992 ± 0.0007	0.9190 ± 0.0087	0.7156 ± 0.0000
Midterm-2018	0.9988 ± 0.0002	1.0000 ± 0.0000	1.0000 ± 0.0000	0.9999 ± 0.0000	0.6617 ± 0.0048

6.2 Результаты по F1-мере

В таблице 6.2 представлены значения F1-меры для табличных методов. В целом, распределение лидеров повторяет результаты по AUPRC:

XGBoost лидирует на 8 из 12 датасетов, достигая наилучших значений на Midterm-2018 (0.998), Elliptic (0.995) и PaySim (0.884).

Случайный лес (RF) занимает первое место на четырёх датасетах: Credit Card Fraud (0.829), AIZBank (0.579), Amazon Reviews (0.856) и MTAB (0.858). На Click Fraud RF также заметно опережает XGBoost (0.344 против 0.327).

Наибольшее расхождение между AUPRC и F1 наблюдается на PaySim: RF имеет AUPRC 0.909, но F1 составляет всего 0.859, а XGBoost при AUPRC 0.946 достигает F1 = 0.884. Это объясняется тем, что оптимальный по F1 порог на валидации даёт консервативные решения, снижая полноту в пользу точности (precision). Для сильно несбалансированных задач (Click Fraud, IR=440) F1-мера всех методов не превышает 0.35, что отражает объективную сложность обнаружения мошенничества при экстремальном дисбалансе.

MLP значительно уступает ансамблевым методам на всех датасетах, особенно на Cresci-2017 (0.871 против 0.990) и Yelp Reviews (0.600 против 0.768). Исключение составляет Social Honeypot, где MLP (0.940) практически сравним с RF (0.942) и XGBoost (0.943).

Логистическая регрессия (LR) показывает приемлемые результаты только на датасетах с низким дисбалансом: Midterm-2018 (0.992), Elliptic (0.956) и Cresci-2017 (0.945). На Click Fraud её F1 падает до 0.051, что подтверждает неэффективность линейных моделей при сильном дисбалансе классов.

Важно отметить, что несмотря на высокие показатели F1 на некоторых датасетах, для сильно несбалансированных задач F1-мера менее показательна поэтому основное внимание в работе уделяется именно площади под PR-кривой (AUPRC) и метрике Precision@K.

Таблица 6.2: Сравнение F1-меры для табличных методов

Датасет	LR	RF	XGBoost	MLP
Credit Card Fraud	0.7660 ± 0.0302	0.8285 ± 0.0271	0.8231 ± 0.0418	0.7734 ± 0.0481
IEEE-CIS	0.4230 ± 0.0035	0.6556 ± 0.0115	0.7584 ± 0.0154	0.4232 ± 0.0032
PaySim	0.5646 ± 0.0089	0.8586 ± 0.0071	0.8838 ± 0.0198	0.6160 ± 0.0190
AIZBank	0.5491 ± 0.0120	0.5794 ± 0.0098	0.5776 ± 0.0149	0.5644 ± 0.0147
Elliptic (Bitcoin)	0.9558 ± 0.0042	0.9942 ± 0.0010	0.9949 ± 0.0009	0.9487 ± 0.0000
Amazon Reviews	0.8544 ± 0.0155	0.8557 ± 0.0259	0.8670 ± 0.0232	0.8633 ± 0.0142
Yelp Reviews	0.4119 ± 0.0055	0.6943 ± 0.0119	0.7679 ± 0.0133	0.5997 ± 0.0165
Click Fraud	0.0508 ± 0.0308	0.3441 ± 0.0586	0.3274 ± 0.0582	0.1000 ± 0.0252
Social Honeypot	0.9015 ± 0.0034	0.9423 ± 0.0026	0.9434 ± 0.0033	0.9400 ± 0.0039
MGTAB	0.8105 ± 0.0099	0.8582 ± 0.0074	0.8575 ± 0.0114	0.8184 ± 0.0083
Cresci-2017	0.9454 ± 0.0054	0.9899 ± 0.0032	0.9906 ± 0.0031	0.8714 ± 0.0188
Midterm-2018	0.9921 ± 0.0006	0.9979 ± 0.0002	0.9980 ± 0.0003	0.9965 ± 0.0006

6.3 Результаты по Precision@K

Таблица 6.3 содержит значения Precision@K для табличных методов, где K равно числу мошеннических объектов в тестовой выборке. Эта метрика имитирует работу реальной системы алертинга: оценивается доля верно обнаруженных мошенников среди K наиболее подозрительных объектов.

XGBoost демонстрирует наивысшую Precision@K на большинстве датасетов: Credit Card Fraud (0.797), IEEE-CIS (0.742), PaySim (0.879), Yelp Reviews (0.771), Click Fraud (0.324), MTAB (0.857), Cresci-2017 (0.991) и Midterm-2018 (0.998). Это подтверждает, что XGBoost не только хорошо ранжирует объекты, но и уверенно выделяет верхний процент подозрительных транзакций, что критически важно для практических систем.

Случайный лес (RF) лидирует на Credit Card Fraud (0.811), Amazon Reviews (0.854) и Click Fraud (0.359), где он заметно опережает XGBoost. На MTAB RF также показывает высокий результат (0.839), уступая лишь XGBoost (0.857).

MLP на многих датасетах даёт Precision@K, сравнимую с LR, но значительно уступает ансамблевым методам. Наибольший разрыв наблюдается на Cresci-2017 (0.834 против 0.991 у XGBoost) и Yelp Reviews (0.601 против 0.771).

VAE как полуконтролируемый метод показывает наилучшие результаты на Elliptic (0.902) и Midterm-2018 (0.813), что подтверждает его способность выделять аномалии даже без использования разметки. Однако на сильно несбалансированных данных (Click Fraud, IEEE-CIS) его Precision@K падает до 0.024 и 0.119 соответственно.

Логистическая регрессия (LR) ожидаемо уступает всем методам на сложных датасетах: Click Fraud (0.059), IEEE-CIS (0.419) и Yelp Reviews (0.397). Исключение составляют Midterm-2018 (0.989) и Cresci-2017 (0.942), где LR показывает высокие значения благодаря информативности признаков.

Таким образом, высокая Precision@K при XGBoost и RF имеет важное практическое значение: при ограниченном бюджете на ручную проверку (например, 100 транзакций в день) эти модели позволяют обнаружить максимальное количество мошеннических операций, минимизируя ложные срабатывания. Это особенно актуально для организаций с ограниченными ресурсами отдела фрод-мониторинга.

Таблица 6.3: Сравнение Precision@K для табличных методов

Датасет	LR	RF	XGBoost	MLP	VAE
Credit Card Fraud	0.7541 ± 0.0232	0.8108 ± 0.0320	0.7973 ± 0.0444	0.7703 ± 0.0331	0.6757 ± 0.0598
IEEE-CIS	0.4185 ± 0.0037	0.6479 ± 0.0119	0.7418 ± 0.0156	0.4110 ± 0.0027	0.1190 ± 0.0467
PaySim	0.5291 ± 0.0114	0.8411 ± 0.0121	0.8789 ± 0.0202	0.6028 ± 0.0290	0.2995 ± 0.0629
AIZBank	0.5324 ± 0.0114	0.5521 ± 0.0092	0.5609 ± 0.0140	0.5498 ± 0.0116	0.2049 ± 0.0117
Elliptic (Bitcoin)	0.9474 ± 0.0062	0.9935 ± 0.0008	0.9945 ± 0.0006	0.8997 ± 0.0011	0.9020 ± 0.0009
Amazon Reviews	0.8407 ± 0.0222	0.8537 ± 0.0178	0.8618 ± 0.0236	0.8455 ± 0.0224	0.5886 ± 0.0413
Yelp Reviews	0.3968 ± 0.0092	0.6952 ± 0.0123	0.7705 ± 0.0136	0.6010 ± 0.0153	0.2804 ± 0.0080
Click Fraud	0.0588 ± 0.0322	0.3588 ± 0.0776	0.3235 ± 0.0322	0.1118 ± 0.0506	0.0235 ± 0.0118
Social Honeypot	0.8912 ± 0.0043	0.9423 ± 0.0028	0.9439 ± 0.0029	0.9405 ± 0.0031	0.7378 ± 0.0046
MGTAB	0.7976 ± 0.0120	0.8393 ± 0.0126	0.8568 ± 0.0093	0.8102 ± 0.0116	0.3092 ± 0.0088
Cresci-2017	0.9423 ± 0.0041	0.9909 ± 0.0030	0.9909 ± 0.0034	0.8339 ± 0.0189	0.4304 ± 0.0195
Midterm-2018	0.9894 ± 0.0009	0.9979 ± 0.0003	0.9980 ± 0.0004	0.9962 ± 0.0005	0.8128 ± 0.0034

6.4 Анализ по доменам

6.4.1 Финансовые транзакции

Среди финансовых датасетов лучшие результаты достигнуты XGBoost. На Credit Card Fraud и PaySim ансамбли превосходят LR на 9–12 п.п. по AUPRC. На IEEE-CIS разрыв между XGBoost и LR достигает 48 п.п. (0.798 против 0.316). Это объясняется высокой размерностью (394 признака), где нелинейные модели имеют преимущество. VAE на финансовых данных неэффективен (AUPRC близок к 0), за исключением PaySim (0.175).

6.4.2 Электронная коммерция

На Amazon Reviews и Yelp Reviews XGBoost уверенно лидирует. На Amazon все методы показывают хорошие результаты (AUPRC > 0.87), но XGBoost (0.904) превосходит RF (0.889) и MLP (0.889). На Yelp разрыв между XGBoost (0.871) и RF (0.750) значителен. Click Fraud – самый сложный датасет в домене (IR=440). XGBoost достигает AUPRC 0.401, что более чем в 7 раз лучше LR (0.055).

6.4.3 Социальные сети

Здесь наблюдается интересная картина. На Social HoneyPot, Cresci-2017 и Midterm-2018 ансамблевые методы достигают почти идеальных значений ($AUPRC > 0.988$). Графовые методы (GraphSAGE, GCN, GAT) на MGTab показывают смешанные результаты: GraphSAGE достигает AUPRC 0.826, а GCN и GAT – около 0.3. Это объясняется тем, что MGTab требует мульти-реляционного представления и текстовых эмбедингов, которые не использовались. На трёх других датасетах социальных сетей графовые методы не применялись из-за отсутствия графовой структуры. VAE на Cresci-2017 и Midterm-2018 даёт очень низкие значения (0.072 и 0.000), что указывает на неспособность выделить аномалии.

6.5 Результаты графовых методов

Графовые методы (GraphSAGE, GCN, GAT) применялись на четырёх датасетах с естественной графовой структурой: Elliptic (Bitcoin), Amazon Reviews, Yelp Reviews и MGTab. В таблицах .9, .7 и .8 Приложения А представлены результаты трёх графовых архитектур.

Таблица 6.4: Сравнение графовых методов по AUPRC

Датасет	GraphSAGE	GCN	GAT
Elliptic (Bitcoin)	0.9964	0.9939	0.9969
Amazon Reviews	0.8125	0.5435	0.5599
Yelp Reviews	0.5651	0.5974	0.6659
MGTab	0.8260	0.3070	0.2908

Сравнение графовых методов позволяет сделать следующие выводы:

- **GraphSAGE** является наиболее устойчивым методом, показывая высокие результаты на всех четырёх датасетах. Особенно заметно его превосходство на MGTab (0.826 против 0.307 у GCN и 0.291 у GAT), что объясняется индуктивным характером обучения и способностью работать с разреженными графами.
- **GAT** благодаря механизму внимания достигает лучшего результата на Yelp Reviews (0.666 против 0.597 у GCN и 0.565 у GraphSAGE). Это подтверждает, что внимание позволяет модели фокусироваться на наиболее информативных соседях в графах умеренной плотности.
- **GCN** показывает результаты, близкие к GAT на Elliptic и Amazon, но значительно уступает на MGTab. Трансдуктивный характер GCN и равномерное усреднение соседей делают его чувствительным к шумовым связям.

- На **MGTAB** только GraphSAGE демонстрирует приемлемое качество (AUPRC 0.826), в то время как GCN и GAT работают практически на уровне случайного классификатора. Это указывает на то, что при отсутствии сильного структурного сигнала и наличии шумовых связей индуктивные методы имеют решающее преимущество.
- На **Elliptic** все три метода показывают практически идеальные результаты (AUPRC > 0.99), что объясняется высокой информативностью как табличных признаков, так и графовой структуры Bitcoin-транзакций.

Таким образом, выбор графового метода должен определяться характеристиками данных: для плотных графов предпочтителен GAT, для разреженных и шумовых — GraphSAGE, а GCN занимает промежуточное положение, уступая обоим в сложных сценариях.

6.6 Статистическое тестирование

Для проверки значимости различий между алгоритмами применялся критерий Вилкоксона (непараметрический парный тест) с поправкой Бонферрони на множественное тестирование. Нулевая гипотеза: медианы AUPRC двух алгоритмов одинаковы. Уровень значимости: $\alpha = 0.05$ (после поправки).

Для анализа корреляций между мета-признаками и производительностью алгоритмов использовался ранговый коэффициент корреляции Спирмена. Всего было выполнено $m = 20$ проверок (4 мета-признака $\times$ 5 метрик). После применения поправки Бонферрони ($\alpha_{\text{сборр}} = 0.05/20 = 0.0025$) ни одна из корреляций не достигла статистической значимости. Это означает, что при столь строгом контроле ошибки первого рода выявленные корреляции (например, между $\log_{10} IR$ и преимуществом XGBoost над LR, $\rho = 0.685$, $p = 0.014$) следует рассматривать как ориентировочные, требующие подтверждения на большем объёме данных. Тем не менее, направление и сила этих связей соответствуют теоретическим ожиданиям.

6.7 Анализ вычислительной стоимости

Таблица 6.5 отображает среднее время обучения (в секундах) для каждого алгоритма и датасета.

По времени обучения методы распределились следующим образом. LR и XGBoost ожидаемо быстры на малых и средних датасетах, однако на IEEE-CIS (590 тыс.) XGBoost обучается 16.5 с, LR — 39 с, что уже сопоставимо с MLP (9.7 с) и VAE (2 с). Самым медленным

Таблица 6.5: Среднее время обучения (секунды)

Датасет	LR	RF	XGBoost	MLP	VAE	GraphSAGE	GCN	GAT
Credit Card Fraud	0.23	50.94	1.02	3.36	10.61	—	—	—
IEEE-CIS	39.29	79.34	16.50	9.72	2.01	—	—	—
PaySim	7.60	512.33	21.50	19.77	9.59	—	—	—
AIZBank	0.05	2.14	0.60	8.22	8.46	—	—	—
Elliptic (Bitcoin)	2.53	6.70	2.01	2.11	0.18	19.96	16.39	31.08
Amazon Reviews	0.01	0.81	37.77	1.88	3.53	80.74	240.99	214.17
Yelp Reviews	0.44	4.41	2.62	8.10	9.36	18.22	24.31	68.14
Click Fraud	0.10	3.80	0.47	5.67	1.35	—	—	—
Social Honeybot	0.02	2.47	0.63	6.98	1.54	—	—	—
Cresci-2017	0.09	0.66	0.22	0.91	0.28	—	—	—
Midterm-2018	0.04	2.52	0.36	2.53	0.25	—	—	—
MGTAB	0.50	3.34	1.77	0.50	1.71	314.14	62.03	54.77

оказался случайный лес на PaySim (512 с), что в 24 раза дольше XGBoost (21.5 с). Графовые методы оказались наиболее ресурсоёмкими, однако вели себя по разному в зависимости от конкретного датасета.

7 Анализ и обсуждение

7.1 Проверка гипотез: влияние свойств данных на эффективность алгоритмов

В разделе 3.3.6 были сформулированы гипотезы о том, какие алгоритмы будут эффективны для разных типов данных. Эксперименты подтвердили большинство из них.

- **Экстремальный дисбаланс и табличная структура (Credit Card, PaySim, Click Fraud).** XGBoost со взвешиванием классов действительно показал наилучшие результаты (AUPRC 0.84–0.92), превосходя LR на 0.3–0.4 п.п. при $IR > 100$. VAE в таких условиях оказался неэффективен ($AUPRC \approx 0$). **Гипотеза подтвердилась.**
- **Высокоразмерные данные (IEEE-CIS, 393 признака).** XGBoost и RF ожидаемо превзошли линейные модели (AUPRC 0.80 и 0.69 против 0.40 у LR). MLP (0.41) не дал выигрыша. **Гипотеза подтвердилась.**
- **Графовые датасеты с низким дисбалансом (Amazon, Yelp).** Гипотеза предполагала эффективность GraphSAGE, но эксперимент показал обратное: XGBoost существенно лучше (0.90 против 0.81 на Amazon, 0.87 против 0.57 на Yelp). Причина — oversmoothing в плотных графах. GAT на Yelp дал 0.67, что лучше GraphSAGE, но всё равно хуже XGBoost. **Гипотеза не подтвердилась** — графовые методы не всегда превосходят табличные.
- **Транзакционный граф Elliptic (разреженный, обратный дисбаланс).** GraphSAGE (0.996) и GCN (0.994) показали результаты, сопоставимые с XGBoost (0.999). Граф не дал дополнительного выигрыша, но и не ухудшил качество. **Гипотеза частично подтвердилась** — граф не повредил, но и не улучшил.
- **MGTAВ (наличие признаков узлов и графа).** XGBoost на 788 числовых признаках достиг AUPRC 0.909, GraphSAGE — 0.826. GCN и GAT провалились (0.31, 0.29). Графовая структура без текстовых эмбедингов не дала преимущества. **Гипотеза о применимости всех методов верна, но лидирует табличный XGBoost.**
- **Сбалансированные и маломерные датасеты (Social Honeypot, AIZBank).** LR и RF действительно достаточны: AUPRC 0.94 и 0.99 (Social Honeypot) и 0.52–0.57 (AIZBank). Сложные методы не дали прироста. **Гипотеза подтвердилась.**

- **Midterm-2018 (обратный дисбаланс, 84% ботов).** XGBoost и RF отработали идеально (AUPRC 1.00), MLP — 0.997. Модели устойчивы к доминированию положительного класса. **Гипотеза подтвердилась.**

7.2 Ключевые количественные закономерности

Дисбаланс классов. Чем выше IR , тем больше преимущество XGBoost над линейными моделями: при $IR > 100$ разница достигает 0.3–0.4 по AUPRC. VAE эффективен только при $IR < 20$; на сильно несбалансированных данных его качество падает до нуля.

Размер выборки. С ростом числа объектов N преимущество MLP перед RF увеличивается, но даже на больших датасетах MLP не превосходит XGBoost.

Графовая структура. Средний AUPRC XGBoost на графовых датасетах (0.893) выше, чем у GraphSAGE (0.800), хотя на MGTAВ и Elliptic графовые методы конкурентоспособны.

7.3 Сравнение семейств алгоритмов: итоги

Линейные модели (LR): применимы только при низком дисбалансе ($IR < 10$) и малой размерности. Их преимущества — скорость и интерпретируемость.

Ансамбли деревьев (RF, XGBoost): наиболее универсальны. XGBoost лучший на 8 из 11 датасетов, особенно при высоком дисбалансе и сложных взаимодействиях.

Глубинное обучение (MLP): не даёт выигрыша над XGBoost на табличных данных, требует больших выборок.

Полуконтролируемые методы (VAE): полезны только при отсутствии разметки и чёткой аномальной структуре (Amazon, Social Honeypot). В остальных случаях — неэффективны.

Графовые методы (GraphSAGE, GCN, GAT): эффективны только если граф несёт дополнительную информацию, не дублирующую признаки. На плотных графах (Amazon, Yelp) уступают XGBoost. GraphSAGE — наиболее устойчивый среди GNN.

7.4 Практические рекомендации

На основе полученных результатов можно предложить следующие ориентиры для выбора алгоритмов в реальных антифрод-системах. При высоком дисбалансе классов ($IR > 100$) безусловным лидером является XGBoost с параметром `scale_pos_weight = min(IR, 500)` и гистограммным методом `tree_method='hist'`: он обеспечивает наилучшее качество при

умеренном времени обучения. Если дисбаланс умеренный ($IR < 50$) и объём данных не превышает 50–100 тысяч записей, более предпочтителен случайный лес — он менее склонен к переобучению на малых выборках и даёт стабильные результаты без сложной настройки. В ситуациях, когда имеется графовая структура, следует сначала оценить качество XGBoost на табличных признаках: если AUPRC уже превышает 0.9, добавление графа вряд ли улучшит результат (как в Elliptic). Если же табличные признаки слабо информативны, а граф разреженный и осмысленный (например, MGTAВ), стоит применять GraphSAGE — он наиболее устойчив среди рассмотренных графовых архитектур.

Если размеченные мошеннические примеры отсутствуют, полезным инструментом может стать VAE, обученный только на нормальных объектах. Он позволяет выделить наиболее подозрительные транзакции, хотя его количественные метрики все таки уступают контролируемым методам. Для высоконагруженных real-time систем, где критична скорость предсказания, оптимальна LR (микросекунды на предсказание) либо XGBoost с небольшим числом деревьев (50–100). Наконец, в условиях жёстких регуляторных требований к интерпретируемости рекомендуется использовать случайный лес или XGBoost в сочетании с SHAP-объяснениями — они обеспечивают баланс между качеством и прозрачностью, тогда как графовые методы и MLP менее пригодны для прямой атрибуции решений на уровне отдельных признаков.

В случаях, когда требуется объяснять, почему модель приняла то или иное решение (например, из-за условий платформ или законодательства), лучше использовать случайный лес или XGBoost с SHAP-объяснениями. Они хорошо сочетают высокое качество и интерпретируемость, тогда как графовые методы и MLP менее пригодны для данных задач.

7.5 Ограничения исследования

- Все эксперименты проведены на статических выборках. В реальных антифрод-системах распределение данных меняется со временем (мошенники адаптируются), поэтому для промышленного внедрения потребуется регулярное переобучение и мониторинг концептуального дрейфа.
- Вычисления проводились на CPU (Apple M4). Использование GPU ускорило бы обучение глубоких и графовых моделей, и позволила бы использовать большее количество ресурсов для, возможно, более оптимального подбора параметров. Однако сравнительные результаты должны были бы остаться прежними.
- В датасетах из домена "Социальные сети" не использовались текстовые эмбединги тви-

тов (хотя они доступны). Использование текстовых данных и поиск мошеннических паттернов в них является отдельной задачей, не стоящей перед нами в данной работе. Также в датасете MGTAВ не учитывались типы рёбер, чтобы датасеты при обработке графовыми методами находились в равных условиях.

- Рассматривалась только бинарная классификация (мошенничество / норма). Многоклассовые задачи (тип мошенничества, степень риска) остались за рамками данной работы.

8 Заключение

8.1 Итоги работы и основные выводы

Проведено систематическое сравнение восьми алгоритмов (LR, RF, XGBoost, MLP, VAE, GraphSAGE, GCN, GAT) на 12 датасетах из финансов, e-commerce и социальных сетей. Унифицированный протокол (стратифицированное разбиение, 5 запусков, единые метрики) обеспечил воспроизводимость.

- 1 **XGBoost** показал лучшие результаты на 8 из 12 датасетов (см. табл. 6.1). Даже на максимально несбалансированном датасете Click Fraud значение AUPRC равняется 0.307, что в 174 раза выше случайного.
- 2 **Случайный лес** уступает XGBoost в среднем на 2–5 процентных пункта по AUPRC, но на больших данных обучается быстрее и реже переобучается на малых выборках.
- 3 **Графовые методы** полезны не всегда. GraphSAGE на MGTAВ (0.826) заметно лучше GCN и GAT (0.31 и 0.29), но на Amazon и Yelp все графовые модели проигрывают XGBoost.
- 4 **MLP** ни разу не превзошёл XGBoost. **VAE** даёт приемлемые результаты только когда почти нет размеченных мошеннических примеров (Elliptic, Credit Card, Amazon), на остальных датасетах его качество близко к нулю.

8.2 Вклад в область

Данная работа вносит несколько вкладов как в методологию сравнительного анализа алгоритмов обнаружения мошенничества, так и в практические рекомендации для их выбора.

Методологический вклад. Разработан унифицированный пайплайн предобработки, разбиения и оценки, который может быть использован в качестве основы для последующих бенчмарков. Предложен подход к количественной оценке влияния характеристик данных (объём, дисбаланс, размерность, наличие графа) на производительность алгоритмов через корреляционный анализ мета-признаков. Впервые выполнено систематическое кросс-доменное сравнение трёх семейств методов — классических (логистическая регрессия, случайный лес, XGBoost), глубинного обучения (MLP, VAE) и графовых нейронных сетей (GraphSAGE, GCN, GAT) — на единой выборке из 12 датасетов, охватывающих финансовые транзакции, электронную коммерцию и социальные сети.

Практический вклад. На основе эмпирических результатов сформулированы конкретные правила выбора алгоритма в зависимости от свойств нового набора данных: при высоком дисбалансе рекомендуется XGBoost со взвешиванием классов; для малых выборок — случайный лес; при наличии разреженного графа и слабых табличных признаках — GraphSAGE; при отсутствии разметки — VAE. Эти рекомендации адресованы начинающим специалистам по анализу данных, разрабатывающим антифрод-системы.

Воспроизводимость и открытость. Все этапы работы — от загрузки и предобработки датасетов до обучения моделей и расчёта метрик — реализованы в виде скриптов на Python с использованием библиотек scikit-learn, XGBoost, PyTorch и PyTorch Geometric. Исходный код, а также обработанные версии датасетов доступны в публичном репозитории, что обеспечивает полную воспроизводимость результатов и позволяет другим исследователям использовать предложенную методологию для своих задач.

8.3 Направления дальнейших исследований

Адаптация к изменяющимся условиям. В реальных антифрод-системах поведение мошенников постоянно эволюционирует. Перспективным направлением является исследование устойчивости алгоритмов к концептуальному дрейфу и разработка методов онлайн-обучения (инкрементальный XGBoost, динамическое обновление графовых эмбеддингов).

Гетерогенные графы. В датасете MGTAВ присутствуют 7 типов рёбер (подписки, упоминания, ретвиты и др.), которые не использовались в работе. Применение мульти-реляционных моделей может выявить дополнительные закономерности в поведении ботов и повысить качество детекции.

Федеративное обучение. Финансовые организации не могут обмениваться конфиденциальными данными, но совместное обучение моделей без раскрытия информации (федеративный подход) позволило бы улучшить обнаружение мошеннических схем, действующих через несколько банков.

Обработка текстовой информации. Интеграция текстовых эмбеддингов (BERT, RoBERTa) для анализа твитов в датасетах социальных сетей (MGTAВ, Cresci-2017) может значительно повысить качество детекции ботов, особенно для графовых методов.

Расширение мета-обучающей выборки. Для построения более надёжной мета-модели необходимо провести эксперименты на 30–50 датасетах. Это позволит выявить устойчивые корреляции и повысить точность рекомендаций.

Интерпретируемость В условиях регуляторных требований разработка методов ин-

терпретации предсказаний для графовых нейронных сетей (GNNE explainer, PGExplainer) и адаптация SHAP для мульти-реляционных графов остаётся актуальной задачей.

Сопоставимость датасетов. В работе не использовались типы рёбер и текстовые эмбединги MGTAВ, чтобы обеспечить единые условия сравнения с другими датасетами, где такая информация отсутствует. Отдельное исследование на обогащённых данных позволило бы оценить, какой вклад вносит каждый тип информации.

Таким образом, работа закладывает основу для обоснованного выбора алгоритмов обнаружения мошенничества и открывает перспективные направления для будущих исследований.

Список литературы

- [1] Esraa Alomari и др. «A Review of Artificial Intelligence for Financial Fraud Detection». В: *Applied Sciences* 16.4 (2026), с. 1931. DOI: [10.3390/app16041931](https://doi.org/10.3390/app16041931). URL: <https://www.mdpi.com/2076-3417/16/4/1931>.
- [2] Tariq Bashir и др. «An extensive experimental comparison of machine and deep learning methods for credit and bank fraud detection». В: т. 88. 2026, с. 109190. DOI: [10.1016/j.frl.2025.109190](https://doi.org/10.1016/j.frl.2025.109190). URL: <https://www.sciencedirect.com/science/article/abs/pii/S1544612325024390>.
- [3] Nazrin Bayramova, Elkhana Karimzada и Elmir Adilzade. «Transductive vs. Inductive Graph Learning for Illicit Bitcoin Transaction Detection». В: *Journal of Computing Sciences and Digital Technologies* 2 (2025). DOI: [10.30546/UNECCSDT.2025.02.1016](https://doi.org/10.30546/UNECCSDT.2025.02.1016). URL: <https://journals.unec.edu.az/jcsdt/article/view/148>.
- [4] Siddhartha Bhattacharyya, Sanjeev Jha, Kurian Tharakunnel и J. Christopher Westland. «Data mining for credit card fraud: A comparative study». В: *Decision Support Systems* 50.3 (2011), с. 602—613. DOI: [10.1016/j.dss.2010.08.008](https://doi.org/10.1016/j.dss.2010.08.008). URL: <https://doi.org/10.1016/j.dss.2010.08.008>.
- [5] Muhammad Bhutta и Abid Mehmood. «Privacy-Preserving Synthetic Data Generation for Federated Learning in Imbalanced Credit Card Fraud Detection: A Comparative Analysis of SMOTE vs. GAN Approaches». В: *Annual Research Symposium*. 2026. URL: <https://scholar.dsu.edu/research-symposium/85/>.
- [6] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall и W. Philip Kegelmeyer. «SMOTE: Synthetic Minority Over-sampling Technique». В: *Journal of Artificial Intelligence Research* 16 (2002), с. 321—357. DOI: [10.1613/jair.953](https://doi.org/10.1613/jair.953).
- [7] Tianqi Chen и Carlos Guestrin. «XGBoost: A Scalable Tree Boosting System». В: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, с. 785—794. DOI: [10.1145/2939672.2939785](https://doi.org/10.1145/2939672.2939785). URL: <https://xgboost.readthedocs.io/>.
- [8] P. Choudhary и др. «Diffusion-based minority augmentation and confidence-calibrated tabular learning for imbalanced rare-event classification». В: *Information Systems* 140 (2026), с. 102716. DOI: [10.1016/j.is.2026.102716](https://doi.org/10.1016/j.is.2026.102716). URL: <https://www.sciencedirect.com/science/article/abs/pii/S030643792600030X>.

- [9] Rongkun Cui и др. «Bridging Cognitive Neuroscience and Graph Intelligence: Hippocampus-Inspired Multi-View Hypergraph Learning for Web Finance Fraud». В: *arXiv preprint arXiv:2601.11073* (2026). URL: <https://arxiv.org/abs/2601.11073>.
- [10] Andrea Dal Pozzolo, Olivier Caelen и Gianluca Bontempi. «When is undersampling effective in unbalanced classification tasks?» В: *Pattern Recognition Letters* 62 (2015), с. 1—7. DOI: [10.1016/j.patrec.2015.03.019](https://doi.org/10.1016/j.patrec.2015.03.019).
- [11] Andrea Dal Pozzolo, Olivier Caelen, Reid A. Johnson и Gianluca Bontempi. «Calibrating probability with undersampling for unbalanced classification». В: *Proceedings of the IEEE Symposium on Computational Intelligence and Data Mining (CIDM)* (2015). Данные ULB Credit Card Fraud Dataset доступны на Kaggle, с. 159—166. URL: <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>.
- [12] Yingdong Dou, Zhiwei Liu, Li Sun, Yutong Deng, Hao Peng и Philip S. Yu. «Enhancing graph neural network-based fraud detectors against camouflaged fraudsters». В: *Proceedings of the 29th ACM International Conference on Information and Knowledge Management*. 2020, с. 315—324. DOI: [10.1145/3340531.3411903](https://doi.org/10.1145/3340531.3411903). URL: <https://doi.org/10.1145/3340531.3411903>.
- [13] Matthias Fey и Jan E. Lenssen. «Fast Graph Representation Learning with PyTorch Geometric». В: *ICLR Workshop on Representation Learning on Graphs and Manifolds*. 2019. URL: <https://pytorch-geometric.readthedocs.io/>.
- [14] Justin Gilmer, Samuel S. Schoenholz, Patrick F. Riley, Oriol Vinyals и George E. Dahl. «Neural Message Passing for Quantum Chemistry». В: *Proceedings of the 34th International Conference on Machine Learning*. 2017, с. 1263—1272.
- [15] Global Anti-Scam Alliance (GASA). *Global Scam Losses Reach \$1.03 Trillion in 2024*. дата обращения: 19.04.2026. 2024. URL: <https://www.feedzai.com/resource/global-state-of-scams-report-2024/>.
- [16] Léo Grinsztajn, Edouard Oyallon и Gaël Varoquaux. «Why do Tree-based Models Still Outperform Deep Learning on Tabular Data?» В: *Advances in Neural Information Processing Systems*. Т. 35. 2022, с. 507—520.
- [17] William L. Hamilton, Rex Ying и Jure Leskovec. «Inductive representation learning on large graphs». В: *Advances in Neural Information Processing Systems*. Т. 30. 2017, с. 1024—1034. URL: <https://papers.nips.cc/paper/6703-inductive-representation-learning-on-large-graphs>.

- [18] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt, Ralf Gommers, Pauli Virtanen, David Cournapeau, Eric Wieser, Julian Taylor, Sebastian Berg, Nathaniel J. Smith, Robert Kern, Matti Picus, Stephan Hoyer, Marten H. van Kerkwijk, Matthew Brett, Allan Haldane, Jaime Fernández del Río, Mark Wiebe, Pearu Peterson, Pierre Gérard-Marchant, Kevin Sheppard, Tyler Reddy, Warren Weckesser, Hameer Abbasi, Christoph Gohlke и Travis E. Oliphant. «Array Programming with NumPy». B: *Nature* 585 (2020), с. 357—362. DOI: [10.1038/s41586-020-2649-2](https://doi.org/10.1038/s41586-020-2649-2). URL: <https://numpy.org/doc/>.
- [19] Wei He и др. «Graph-Based Fraud Detection with Dual-Path Graph Filtering». B: *arXiv preprint arXiv:2604.14235* (2026). URL: <https://arxiv.org/abs/2604.14235>.
- [20] Walaa Hilal, S. Andrew Gadsden и John Yawney. «A comprehensive review of machine learning methods for credit card fraud detection». B: *IEEE Access* 10 (2022), с. 108447—108472. DOI: [10.1109/ACCESS.2022.3212891](https://doi.org/10.1109/ACCESS.2022.3212891). URL: <https://ijarsct.co.in/Paper22301.pdf>.
- [21] Kurt Hornik, Maxwell Stinchcombe и Halbert White. «Multilayer Feedforward Networks are Universal Approximators». B: *Neural Networks* 2.5 (1989), с. 359—366. DOI: [10.1016/0893-6080\(89\)90020-8](https://doi.org/10.1016/0893-6080(89)90020-8).
- [22] Xin Huang, Ashish Khetan, Milan Cvitkovic и Zohar Karnin. «TabTransformer: Tabular Data Modeling Using Contextual Embeddings». B: *arXiv preprint arXiv:2012.06678* (2020).
- [23] John D. Hunter. «Matplotlib: A 2D Graphics Environment». B: *Computing in Science & Engineering* 9.3 (2007), с. 90—95. DOI: [10.1109/MCSE.2007.55](https://doi.org/10.1109/MCSE.2007.55). URL: <https://matplotlib.org/stable/>.
- [24] Shubham Joshi и др. «The Fraud Dataset Benchmark and the performance of graph neural networks». B: *arXiv preprint arXiv:2108.11859* (2021). URL: <https://arxiv.org/abs/2108.11859>.
- [25] Diederik P. Kingma и Max Welling. «Auto-Encoding Variational Bayes». B: *Proceedings of the 2nd International Conference on Learning Representations*. 2014.
- [26] Thomas N. Kipf и Max Welling. «Semi-supervised classification with graph convolutional networks». B: *Proceedings of the 5th International Conference on Learning Representations*. 2017. URL: <https://arxiv.org/abs/1609.02907>.
- [27] Hao Li и др. «A graph fraud detection model based on mutual information». B: *Neurocomputing* 663 (2026), с. 131972. DOI: [10.1016/j.neucom.2025.131972](https://doi.org/10.1016/j.neucom.2025.131972). URL: <https://www.sciencedirect.com/science/article/abs/pii/S092523122502644X>.

- [28] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Köpf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai и Soumith Chintala. «PyTorch: An Imperative Style, High-Performance Deep Learning Library». B: 32 (2019), с. 8024—8035. URL: <https://pytorch.org/docs/>.
- [29] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot и Édouard Duchesnay. «Scikit-learn: Machine Learning in Python». B: *Journal of Machine Learning Research* 12 (2011), с. 2825—2830. URL: <https://scikit-learn.org/stable/>.
- [30] The pandas development team. *pandas-dev/pandas: Pandas*. 2024. DOI: [10.5281/zenodo.3509134](https://doi.org/10.5281/zenodo.3509134). URL: <https://pandas.pydata.org/docs/>.
- [31] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser и Illia Polosukhin. «Attention is All You Need». B: *Advances in Neural Information Processing Systems*. T. 30. 2017, с. 5998—6008.
- [32] Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Liò и Yoshua Bengio. «Graph Attention Networks». B: *International Conference on Learning Representations (ICLR)*. 2018. URL: <https://arxiv.org/abs/1710.10903>.
- [33] Chao Wang, Chuanhao Nie и Yunbo Liu. «Evaluating Supervised Learning Models for Fraud Detection: A Comparative Study of Classical and Deep Architectures on Imbalanced Transaction Data». B: *Proceedings of the 2025 3rd International Academic Conference on Management Innovation and Economic Development (MIED 2025)*. Springer, 2025, с. 613—624. URL: https://econpapers.repec.org/bookchap/spradvbcp/978-94-6463-835-6_5f65.htm.
- [34] Y. Wang и др. «Attention-augmented and depthwise separable convolutional message passing for robust fraud detection in large-scale graphs». B: *Journal of Advanced Research* 82 (2026), с. 597—612. DOI: [10.1016/j.jare.2025.08.018](https://doi.org/10.1016/j.jare.2025.08.018). URL: <https://www.sciencedirect.com/science/article/pii/S2090123225004953>.
- [35] Y. Zhao и др. «Detecting credit card fraud from transaction data streams with incremental time-aware liquid recurrent network». B: *Knowledge-Based Systems* 331 (2026), с. 114729.

DOI: 10.1016/j.knosys.2025.114729. URL: <https://www.sciencedirect.com/science/article/abs/pii/S095070512501768X>.

Приложение А. Результаты работы алгоритмов на всех датасетах

Таблица .1: Метрики качества LR на всех датасетах (среднее $\pm$ стандартное отклонение по 5 запускам)

Датасет	AUPRC		AUROC		F1		Prec@K		Best C
	mean	std	mean	std	mean	std	mean	std	
Credit Card Fraud	0.7523	0.0600	0.9793	0.0075	0.7660	0.0302	0.7541	0.0232	1.00
IEEE-CIS	0.4049	0.0037	0.8634	0.0015	0.4230	0.0035	0.4185	0.0037	10.00
PaySim	0.5606	0.0120	0.9897	0.0013	0.5646	0.0089	0.5291	0.0114	0.01
AIZBank	0.5246	0.0128	0.8922	0.0052	0.5491	0.0120	0.5324	0.0114	100.00
Elliptic (Bitcoin)	0.9884	0.0016	0.9034	0.0132	0.9558	0.0042	0.9474	0.0062	1.00
Amazon Reviews	0.8836	0.0182	0.9744	0.0084	0.8544	0.0155	0.8407	0.0222	0.10
Yelp Reviews	0.3885	0.0090	0.7653	0.0063	0.4119	0.0055	0.3968	0.0092	100.00
Click Fraud	0.0457	0.0228	0.8313	0.0204	0.0508	0.0308	0.0588	0.0322	0.01
Social HoneyPot	0.9451	0.0052	0.9427	0.0024	0.9015	0.0034	0.8912	0.0043	100.00
Cresci-2017	0.9624	0.0237	0.9846	0.0067	0.9454	0.0054	0.9423	0.0041	100.00
Midterm-2018	0.9988	0.0002	0.9943	0.0007	0.9921	0.0006	0.9894	0.0009	100.00
MGTAB	0.8550	0.0217	0.9448	0.0056	0.8105	0.0099	0.7976	0.0120	0.10

Таблица .2: Метрики качества RF на всех датасетах (среднее $\pm$ стандартное отклонение по 5 запускам)

Датасет	AUPRC		AUROC		F1		Prec@K		Лучшие параметры
	mean	std	mean	std	mean	std	mean	std	
Credit Card Fraud	0.8406	0.0304	0.9628	0.0114	0.8285	0.0271	0.8108	0.0320	d=30, l=1, sqrt
IEEE-CIS	0.6943	0.0132	0.9338	0.0080	0.6556	0.0115	0.6479	0.0119	d=None, l=1, log2
PaySim	0.9088	0.0136	0.9984	0.0007	0.8586	0.0071	0.8411	0.0121	d=20, l=1, sqrt
AIZBank	0.5687	0.0103	0.9072	0.0042	0.5794	0.0098	0.5521	0.0092	d=None, l=5, sqrt
Elliptic (Bitcoin)	0.9996	0.0001	0.9964	0.0007	0.9942	0.0010	0.9935	0.0008	d=30, l=1, sqrt
Amazon Reviews	0.9086	0.0231	0.9817	0.0077	0.8557	0.0259	0.8537	0.0178	d=None, l=10, None
Yelp Reviews	0.7681	0.0133	0.9260	0.0022	0.6943	0.0119	0.6952	0.0123	d=30, l=3, None
Click Fraud	0.3387	0.0581	0.9245	0.0237	0.3441	0.0586	0.3588	0.0776	d=10, l=3, None
Social HoneyPot	0.9882	0.0010	0.9856	0.0013	0.9423	0.0026	0.9423	0.0028	d=10, l=5, log2
Cresci-2017	0.9995	0.0003	0.9995	0.0003	0.9899	0.0032	0.9909	0.0030	d=20, l=1, log2
Midterm-2018	1.0000	0.0000	0.9999	0.0000	0.9979	0.0002	0.9979	0.0003	d=30, l=1, sqrt
MGTAB	0.8817	0.0066	0.9660	0.0026	0.8582	0.0074	0.8393	0.0126	d=None, l=10, None

Таблица .3: Метрики качества XGBoost (среднее $\pm$ стандартное отклонение по 5 запускам)

Датасет	AUPRC		AUROC		F1		Prec@K	
	mean	std	mean	std	mean	std	mean	std
Credit Card Fraud	0.8156	0.0437	0.9761	0.0094	0.8231	0.0418	0.7973	0.0444
IEEE-CIS	0.8052	0.0157	0.9629	0.0031	0.7584	0.0154	0.7418	0.0156
PaySim	0.9460	0.0153	0.9992	0.0005	0.8838	0.0198	0.8789	0.0202
AIZBank	0.5733	0.0170	0.9084	0.0069	0.5776	0.0149	0.5609	0.0140
Elliptic (Bitcoin)	0.9996	0.0001	0.9970	0.0005	0.9949	0.0009	0.9945	0.0006
Amazon Reviews	0.9145	0.0272	0.9870	0.0043	0.8670	0.0232	0.8618	0.0236
Yelp Reviews	0.8533	0.0131	0.9547	0.0049	0.7679	0.0133	0.7705	0.0136
Click Fraud	0.3073	0.0234	0.9458	0.0190	0.3274	0.0582	0.3235	0.0322
Social Honeypot	0.9884	0.0009	0.9858	0.0011	0.9434	0.0033	0.9439	0.0029
Cresci-2017	0.9992	0.0007	0.9993	0.0007	0.9906	0.0031	0.9909	0.0034
Midterm-2018	1.0000	0.0000	0.9999	0.0000	0.9980	0.0003	0.9980	0.0004
MGTAB	0.9092	0.0041	0.9728	0.0020	0.8575	0.0114	0.8568	0.0093

Таблица .4: Лучшие гиперпараметры XGBoost (найлены по максимуму AUPRC на валидации)

Датасет	learning_rate	n_estimators	max_depth	reg_lambda	subsample	colsample_bytree
Credit Card Fraud	0.10	400	3	10.0	1.0	0.6
IEEE-CIS	0.20	600	9	1.0	1.0	1.0
PaySim	0.10	200	7	1.0	0.8	1.0
AIZBank	0.01	200	7	1.0	0.6	0.6
Elliptic (Bitcoin)	0.05	400	7	1.0	1.0	1.0
Amazon Reviews	0.10	600	3	0.1	1.0	0.8
Yelp Reviews	0.20	400	7	1.0	1.0	0.6
Click Fraud	0.30	800	7	0.1	1.0	1.0
Social Honeypot	0.20	200	3	1.0	0.8	0.6
Cresci-2017	0.10	800	7	0.1	1.0	0.6
Midterm-2018	0.10	600	3	0.1	1.0	0.8
MGTAB	0.05	800	9	1.0	0.8	0.8

Таблица .5: Метрики качества MLP на всех датасетах (среднее $\pm$ стандартное отклонение по 5 запускам)

Датасет	AUPRC		AUROC		F1		Prec@K	
	mean	std	mean	std	mean	std	mean	std
Credit Card Fraud	0.7017	0.0694	0.9431	0.0181	0.7734	0.0481	0.7703	0.0331
IEEE-CIS	0.4106	0.0052	0.8273	0.0064	0.4232	0.0032	0.4110	0.0027
PaySim	0.6338	0.0276	0.9823	0.0074	0.6160	0.0190	0.6028	0.0290
AIZBank	0.5561	0.0116	0.9027	0.0039	0.5644	0.0147	0.5498	0.0116
Elliptic (Bitcoin)	0.9531	0.0019	0.6502	0.0125	0.9487	0.0000	0.8997	0.0011
Amazon Reviews	0.8947	0.0195	0.9802	0.0057	0.8633	0.0142	0.8455	0.0224
Yelp Reviews	0.6532	0.0111	0.8856	0.0042	0.5997	0.0165	0.6010	0.0153
Click Fraud	0.0609	0.0129	0.8690	0.0297	0.1000	0.0252	0.1118	0.0506
Social Honeypot	0.9872	0.0011	0.9842	0.0015	0.9400	0.0039	0.9405	0.0031
Cresci-2017	0.9190	0.0087	0.9222	0.0059	0.8714	0.0188	0.8339	0.0189
Midterm-2018	0.9999	0.0000	0.9994	0.0001	0.9965	0.0006	0.9962	0.0005
MGTAB	0.8773	0.0130	0.9539	0.0054	0.8184	0.0083	0.8102	0.0116

Таблица .6: Метрики качества VAE на всех датасетах (среднее $\pm$ стандартное отклонение по 5 запускам)

Датасет	AUPRC		AUROC		Prec@K	
	mean	std	mean	std	mean	std
Credit Card Fraud	0.6258	0.0902	0.9405	0.0170	0.6757	0.0598
IEEE-CIS	0.1775	0.1702	0.6744	0.0885	0.1190	0.0467
PaySim	0.2753	0.0682	0.8401	0.0112	0.2995	0.0629
AIZBank	0.2035	0.0144	0.6961	0.0161	0.2049	0.0117
Elliptic (Bitcoin)	0.9512	0.0000	0.5000	0.0000	0.9020	0.0009
Amazon Reviews	0.6194	0.0567	0.9426	0.0113	0.5886	0.0413
Yelp Reviews	0.2322	0.0064	0.6448	0.0060	0.2804	0.0080
Click Fraud	0.0134	0.0021	0.8090	0.0183	0.0235	0.0118
Social Honeypot	0.7880	0.0056	0.7915	0.0054	0.7378	0.0046
Cresci-2017	0.7156	0.0000	0.5000	0.0000	0.4304	0.0195
Midterm-2018	0.6617	0.0048	0.0570	0.0226	0.8128	0.0034
MGTAB	0.3607	0.0181	0.5653	0.0156	0.3092	0.0088

Таблица .7: Метрики качества GCN на графовых датасетах (среднее $\pm$ стандартное отклонение по 5 запускам)

Датасет	AUPRC		AUROC		Prec@K	
	mean	std	mean	std	mean	std
Elliptic (Bitcoin)	0.9939	0.0011	0.9665	0.0026	0.9810	0.0008
Amazon Reviews	0.5435	0.0315	0.9063	0.0137	0.5514	0.0263
Yelp Reviews	0.5974	0.0492	0.8878	0.0138	0.5616	0.0398
MGTAB	0.3070	0.0217	0.5463	0.0131	0.2985	0.0196

Таблица .8: Метрики качества GAT на графовых датасетах (среднее $\pm$ стандартное отклонение по 5 запускам)

Датасет	AUPRC		AUROC		Prec@K	
	mean	std	mean	std	mean	std
Elliptic (Bitcoin)	0.9969	0.0004	0.9812	0.0012	0.9851	0.0011
Amazon Reviews	0.5599	0.0449	0.9111	0.0143	0.5385	0.0216
Yelp Reviews	0.6659	0.0230	0.9132	0.0056	0.6250	0.0169
MGTAB	0.2908	0.0138	0.5216	0.0197	0.2810	0.0156

Таблица .9: Метрики качества GraphSAGE на графовых датасетах (среднее $\pm$ стандартное отклонение по 5 запускам)

Датасет	AUPRC		AUROC		Prec@K	
	mean	std	mean	std	mean	std
Elliptic (Bitcoin)	0.9964	0.0014	0.9831	0.0016	0.9863	0.0008
Amazon Reviews	0.8125	0.0353	0.9704	0.0061	0.7989	0.0285
Yelp Reviews	0.5651	0.0539	0.8679	0.0265	0.5321	0.0431
MGTAB	0.8260	0.0227	0.9355	0.0064	0.7727	0.0214